О задаче кластеризации

Евгений Борисов

метрические методы : кластеризация

метрический подход - использование расстояний между объектами

метрика - функция расстояния $\rho: X \times X \to [0, \infty)$

аксиома тождества : $\rho(x, y) = 0 \Leftrightarrow x = y$

симметрия: $\rho(x, y) = \rho(y, x)$

неравенство треугольника: $\rho(x, z) \leqslant \rho(x, y) + \rho(y, z)$

Примеры:

Евклидова метрика: $\rho(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$

метрика Минковского: $\rho(x, y) = \sqrt[n]{\sum_i w_i |x_i - y_i|^n}$

метрика Чебышева: $\rho(x, y) = \max_i |x_i - y_i|$

метрические методы : кластеризация

о задаче: обучение «без учителя» (unsupervised learning)

<u>дано:</u>

X - объекты

$\rho: X \times X \to [0, \infty)$ - функция расстояния (метрика)

<u>найти:</u>

Y - кластеры (метки)

$a: X \to Y$ - кластеризатор

- кластер состоит из близких объектов

- объекты разных кластеров существенно разные

метрические методы : кластеризация

о некорректности (размытости) задачи кластеризации

- недостаточно точная постановка задачи

- много разных критериев качества

- число кластеров обычно заранее не известно

- результат сильно зависит от метрики

- нормировка данных может существенно изменять результат

метрические методы : кластеризация

цели кластеризации

- предварительная обработка данных для упрощения основной задачи

- сжатие данных (оставляем один или несколько объектов от кластера)

- выделить нетипичные объекты

- построение иерархии объектов

метрические методы : кластеризация

типы кластера: кластеры с центром

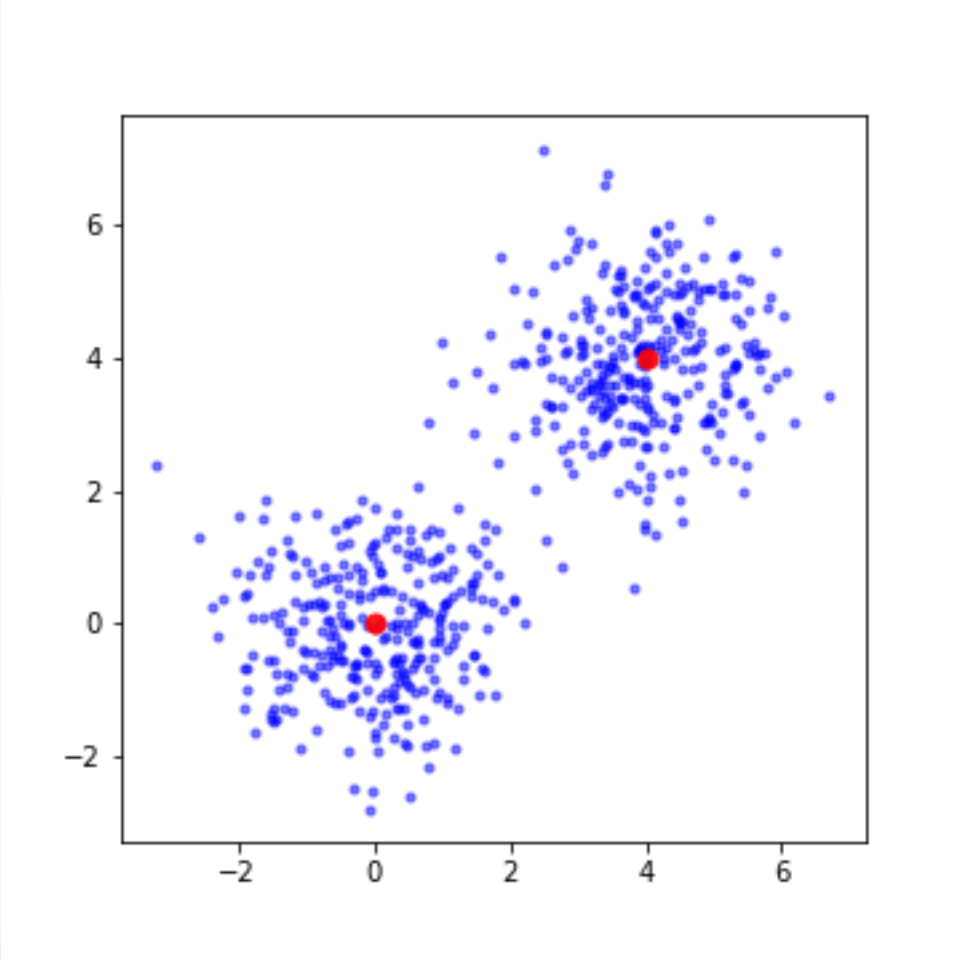

метрические методы : кластеризация

тип кластера: кластеры могут отсутствовать совсем

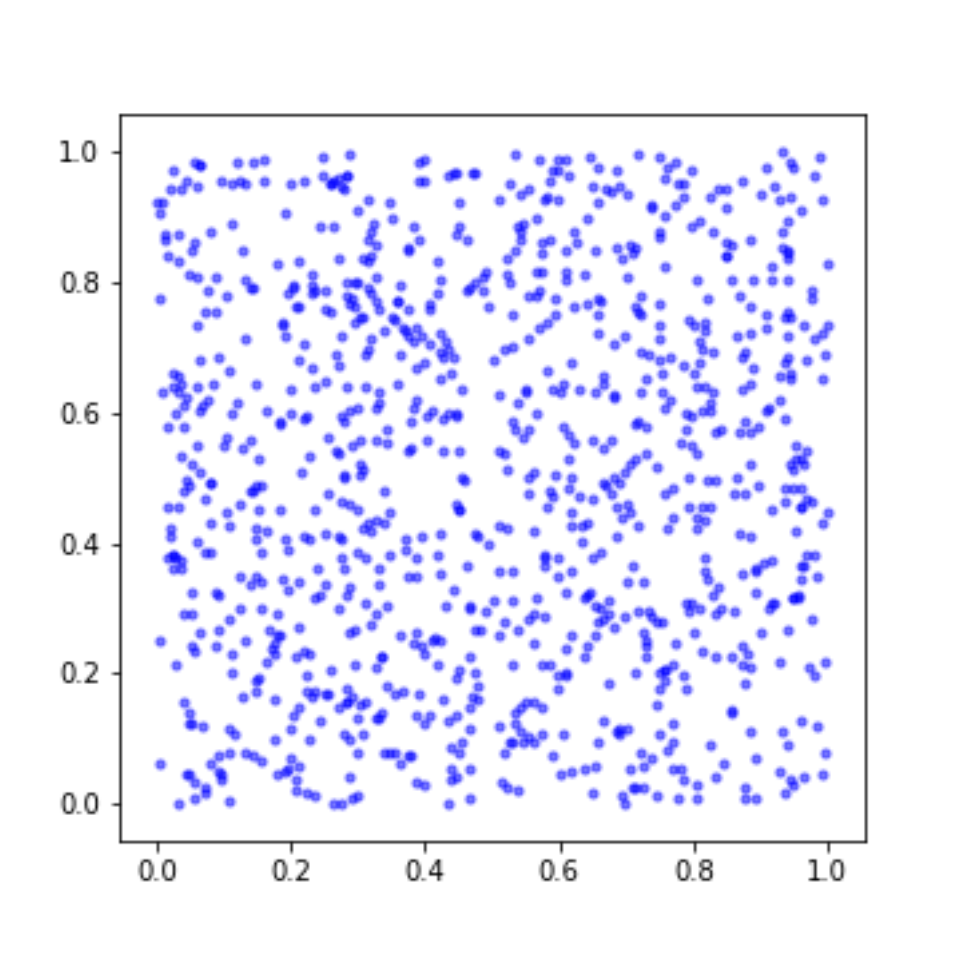

метрические методы : кластеризация

тип кластера: кластеры с перемычками

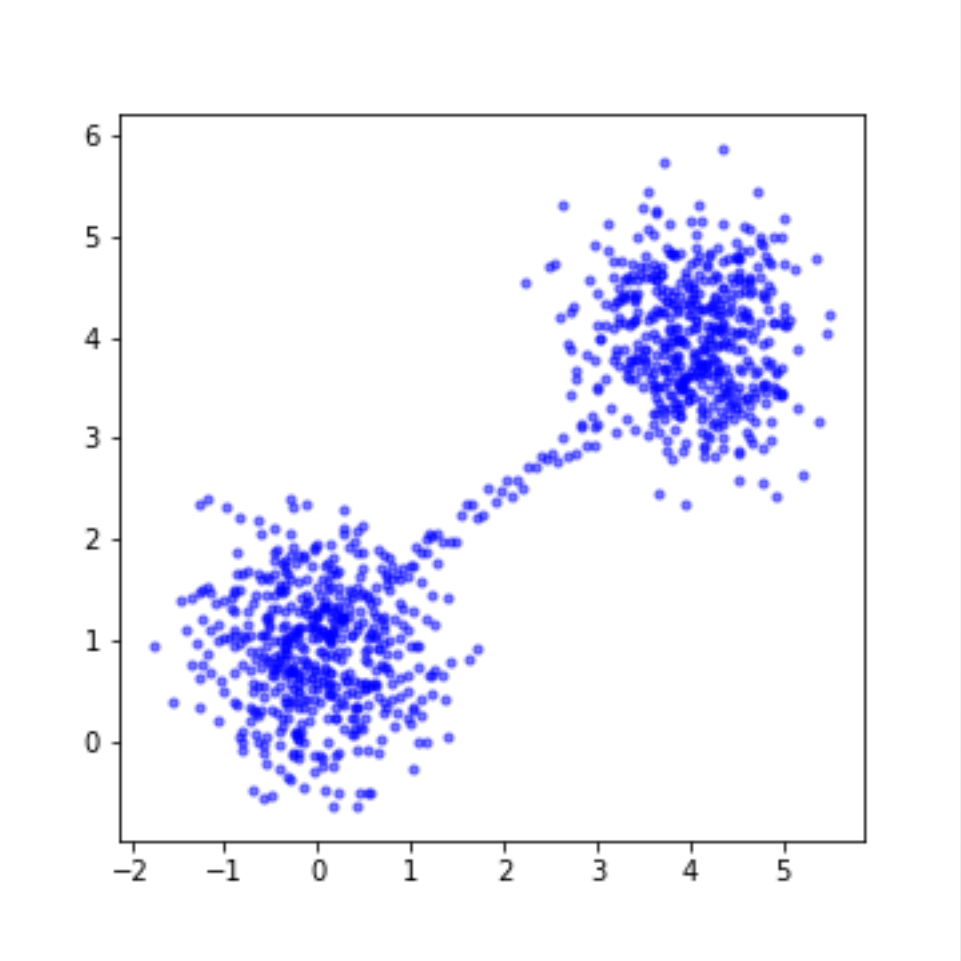

другие типы кластеров:
- могут отсутствовать
- кластеры с центром

метрические методы : кластеризация

тип кластера: кластеры ленточные

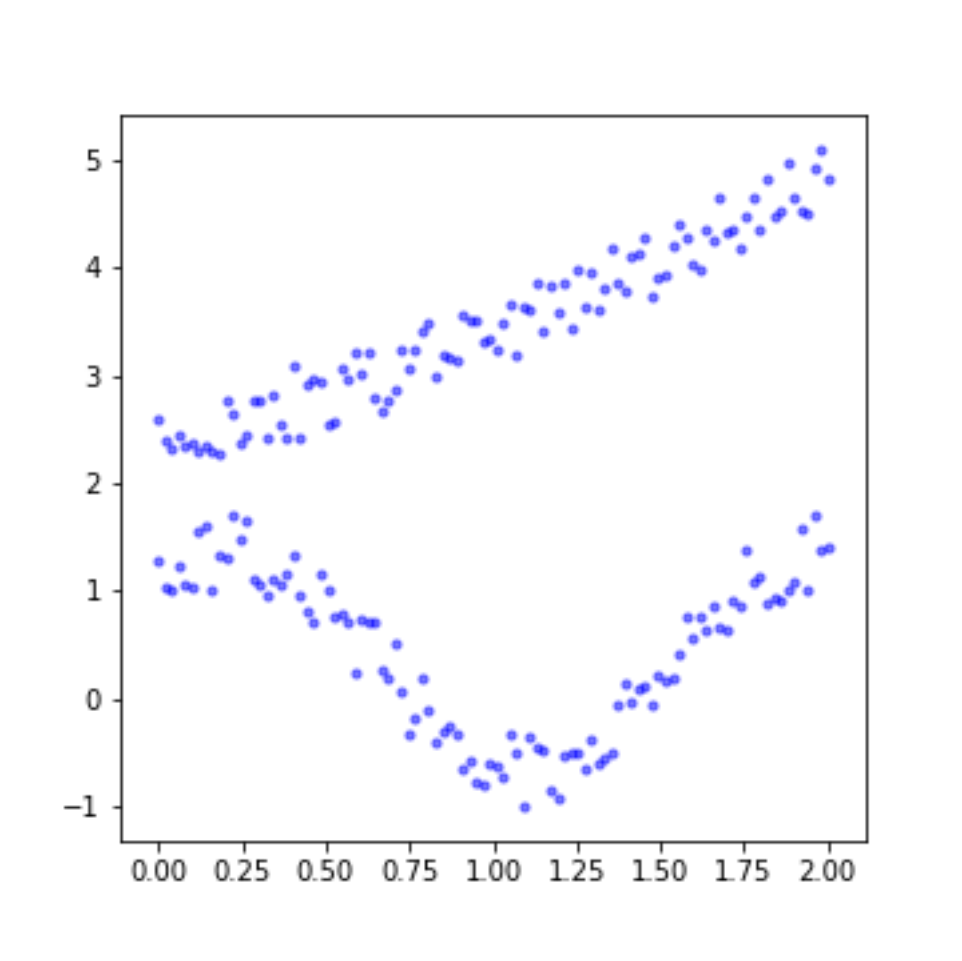

другие типы кластеров:
- могут отсутствовать
- кластеры с центром
- кластеры с перемычками

метрические методы : кластеризация

тип кластера: кластеры с наложением

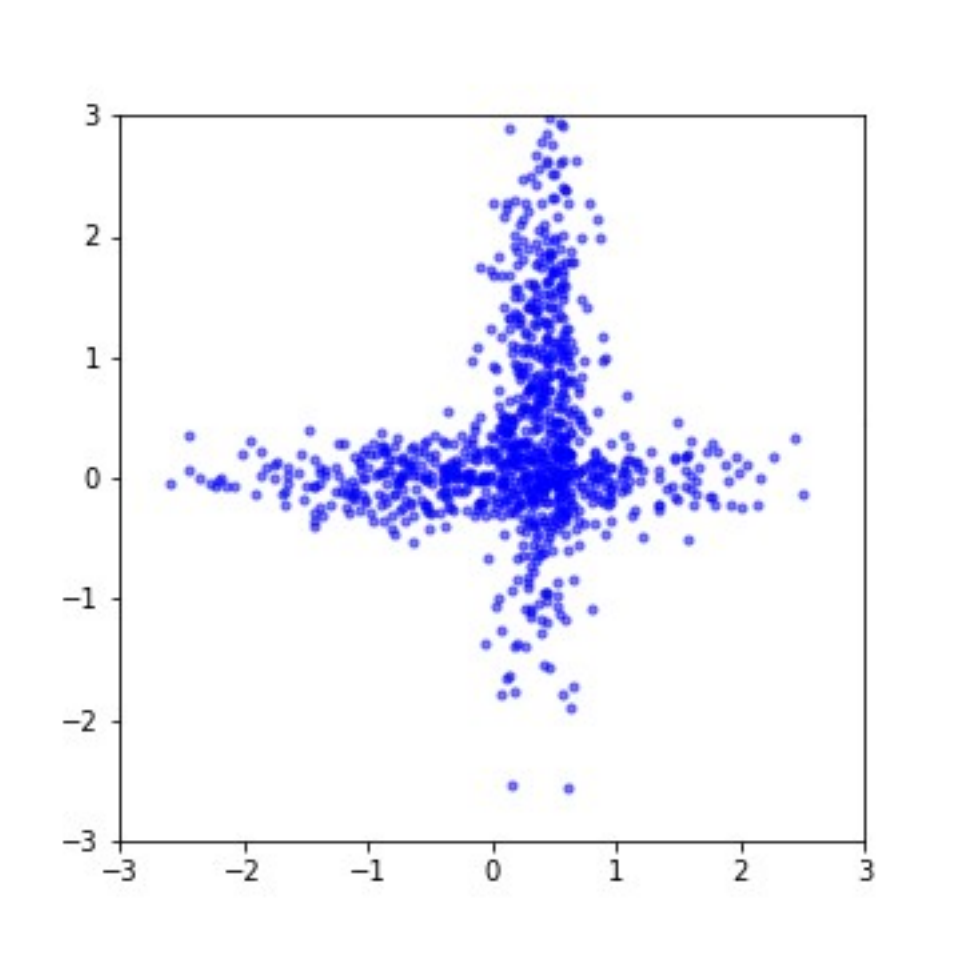

другие типы кластеров:
- могут отсутствовать
- кластеры с центром
- кластеры с перемычками
- кластеры ленточные

метрические методы : кластеризация

тип кластера: кластеры с шумом

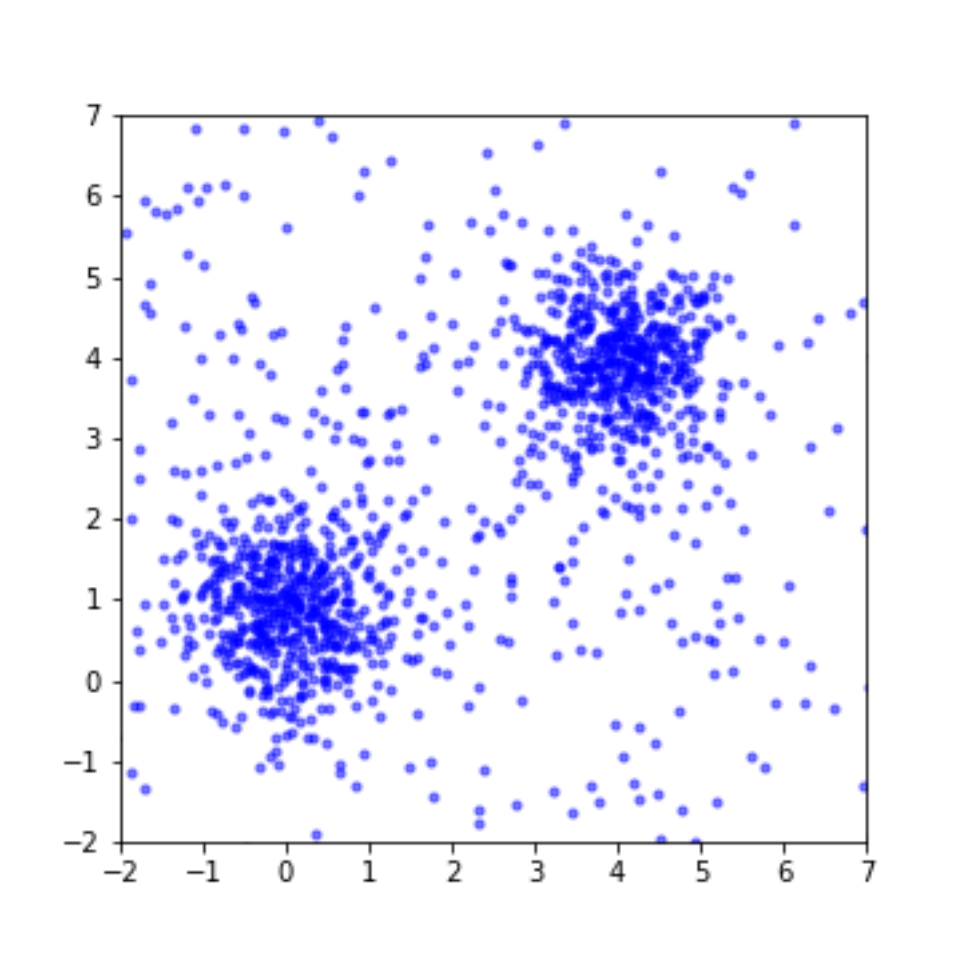

другие типы кластеров:
- могут отсутствовать
- кластеры с центром
- кластеры с перемычками
- кластеры ленточные
- кластеры с наложением

метрические методы : кластеризация

тип кластера: кластеры по типу регулярности

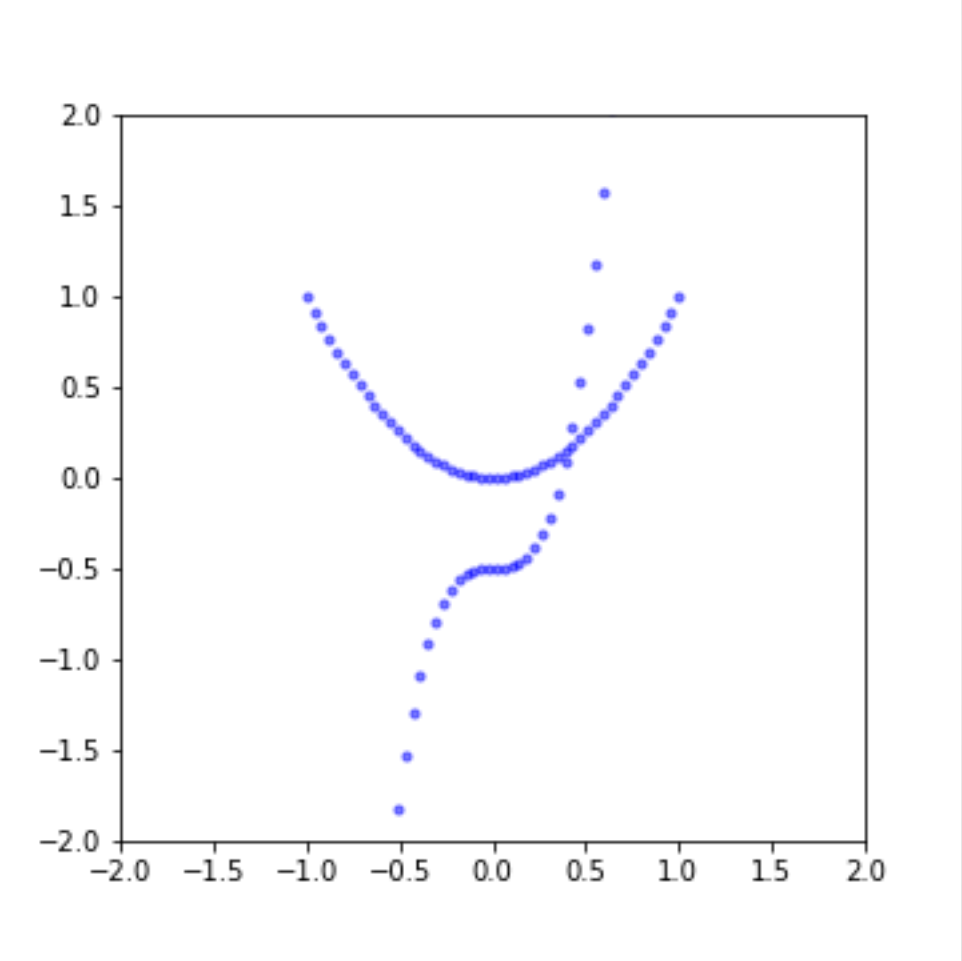

другие типы кластеров:
- могут отсутствовать
- кластеры с центром
- кластеры с перемычками
- кластеры ленточные
- кластеры с наложением
- кластеры с шумом

метрические методы : кластеризация

оценки кластеризации $a: X \to Y$

$$ri = \frac{\sum_{i<j} [a_i = a_j] \rho(x_i, x_j)}{\sum_{i<j} [a_i = a_j]} \to min$$

среднее внутрикластерное расстояние

$$ro = \frac{\sum_{i<j} [a_i \neq a_j] \rho(x_i, x_j)}{\sum_{i<j} [a_i = a_j]} \to max$$

среднее межкластерное расстояние

отношение внутрикластерного и межкластерного расстояний

$$\frac{ri}{ro} \to min$$

метрические методы : кластеризация

метод к-средних (k-means)

количество кластеров как параметр,

цель - найти точки-центроиды

метрические методы : кластеризация

метод к-средних (k-means)

количество кластеров как параметр,

цель - найти точки-центроиды

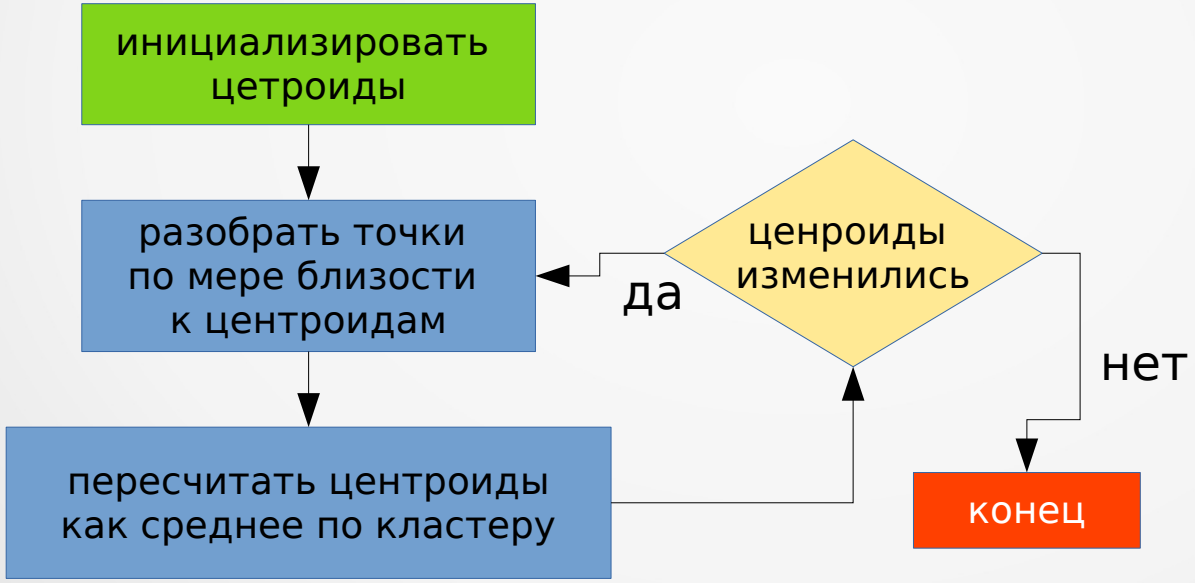

метрические методы : кластеризация

k-means: начальное состояние и результат

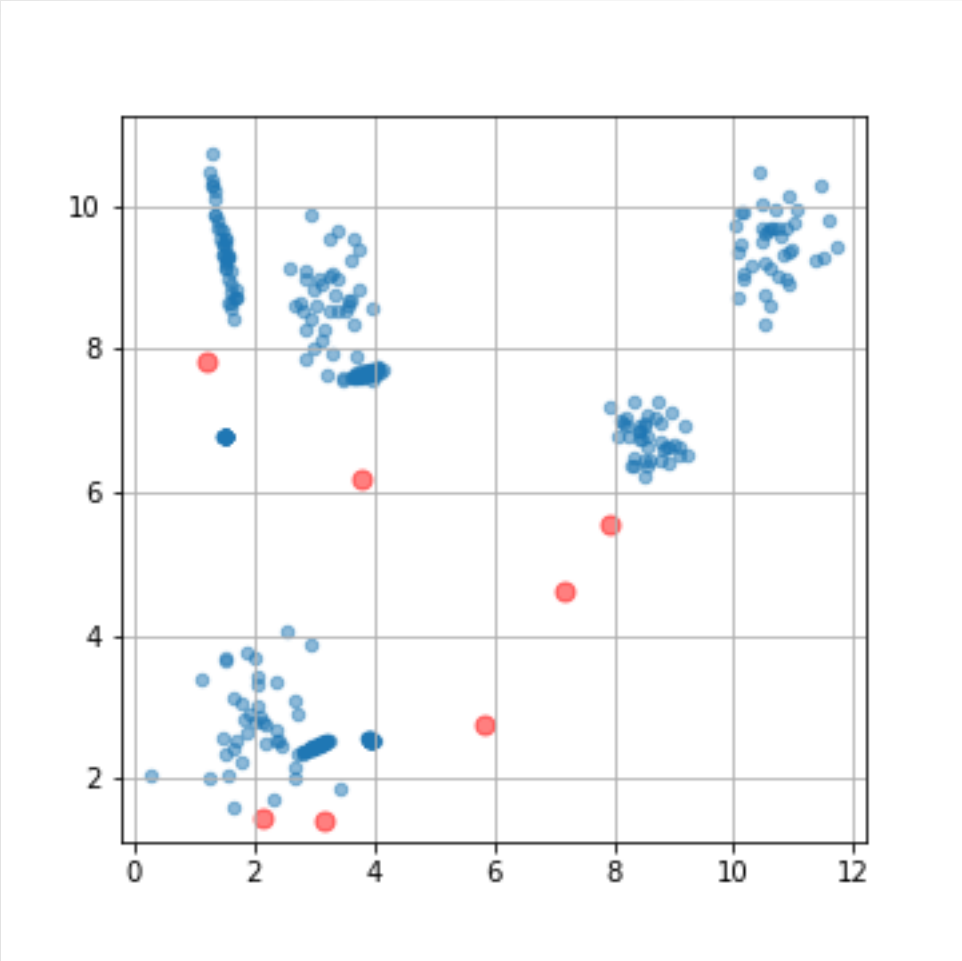

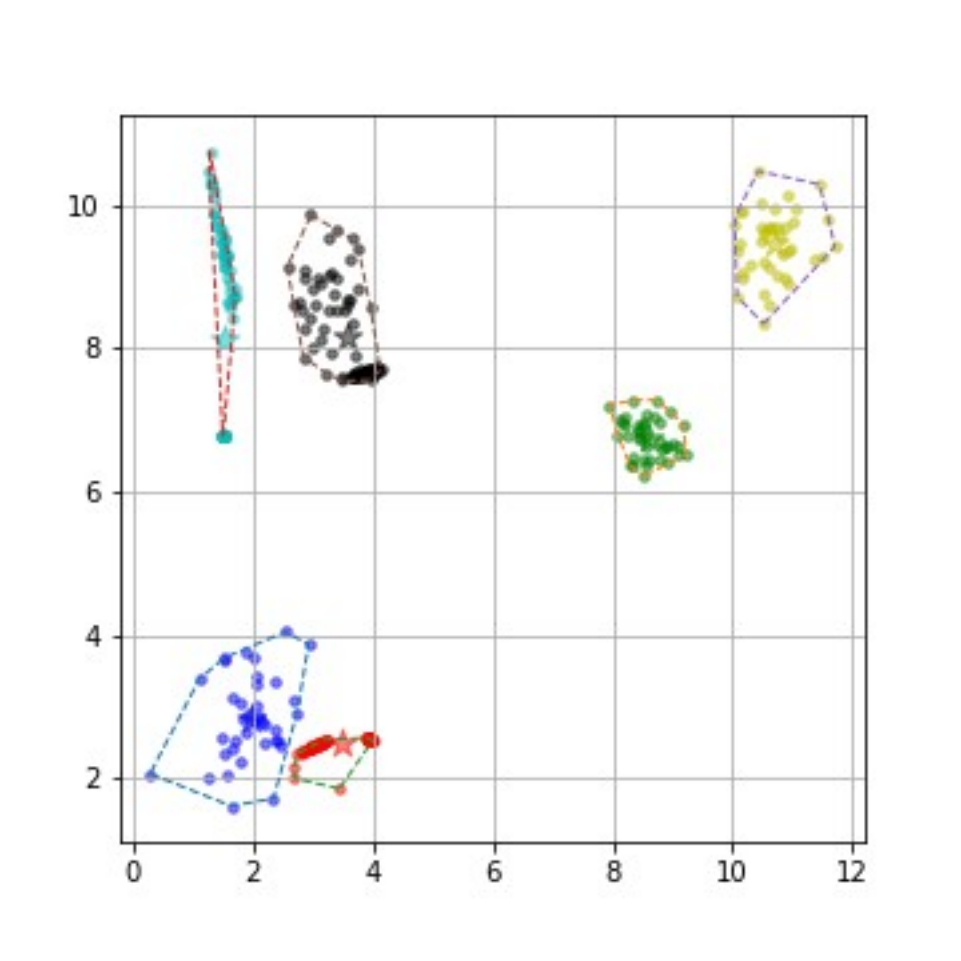

метрические методы : кластеризация

метод MeanShift (ФорЭл - ФОРмальные ЭЛементы)

фиксируем радиус R кластеров,

цель - найти точки-центроиды

метрические методы : кластеризация

метод MeanShift (ФорЭл - ФОРмальные ЭЛементы)

фиксируем радиус R кластеров, цель - найти точки-центроиды

метрические методы : кластеризация

MeanShift (ФорЭл) начальное состояние и результат

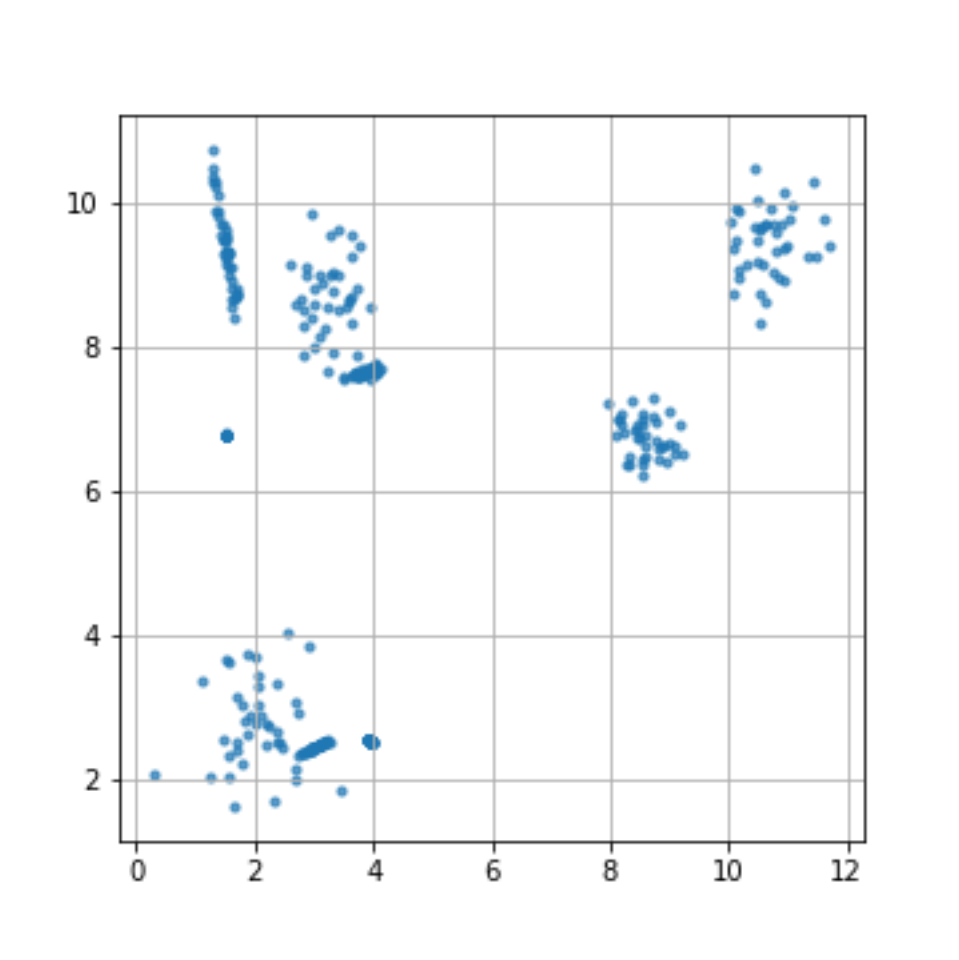

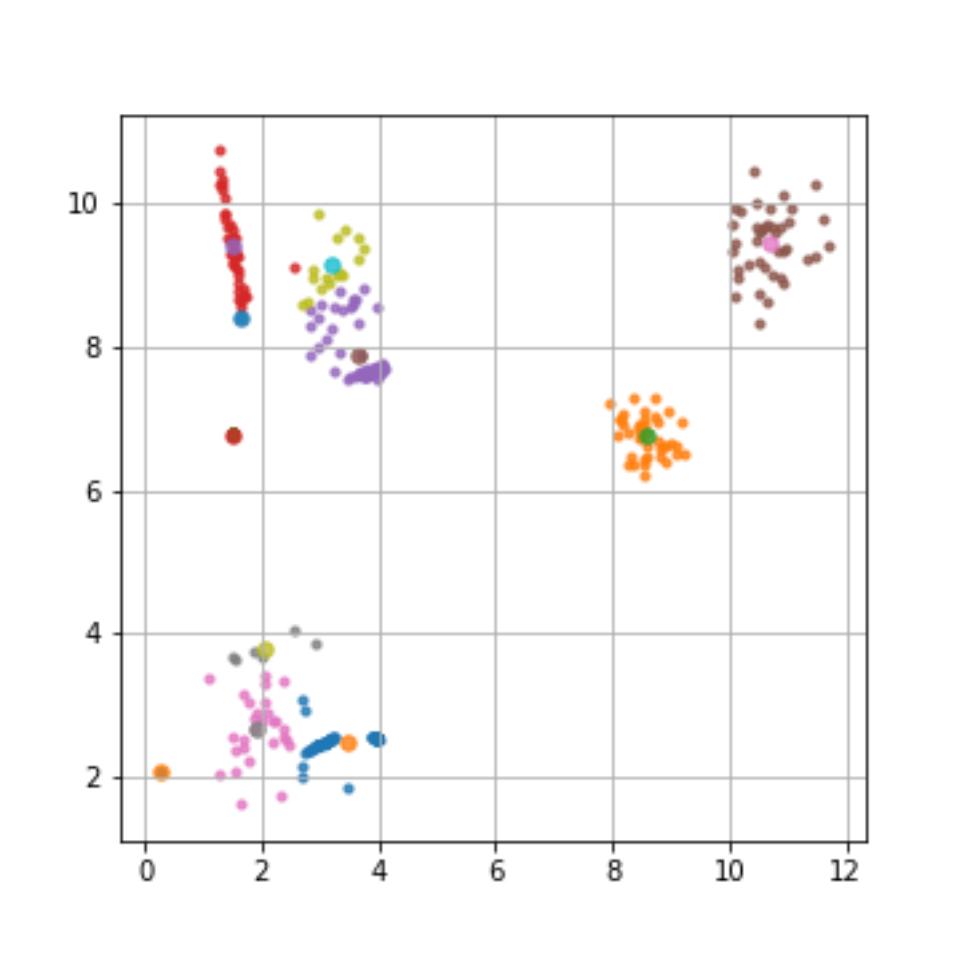

метрические методы : кластеризация

метод КНП (Кратчайший Незамкнутый Путь)

параметр - количество кластеров k

цель - построить ациклический граф на точках

метрические методы : кластеризация

метод КНП (Кратчайший Незамкнутый Путь)

параметр - количество кластеров k

цель - построить ациклический граф на точках

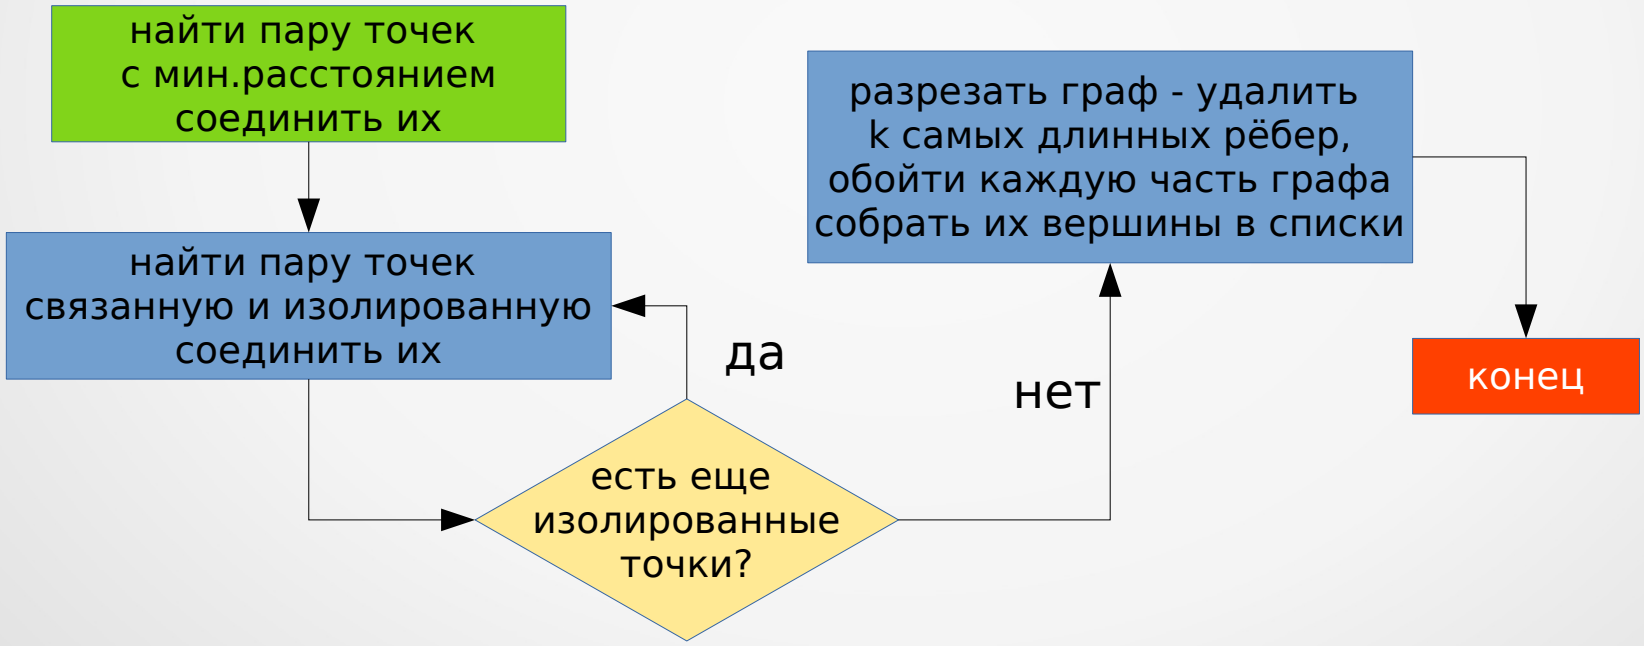

метрические методы : кластеризация

КНП: полный граф

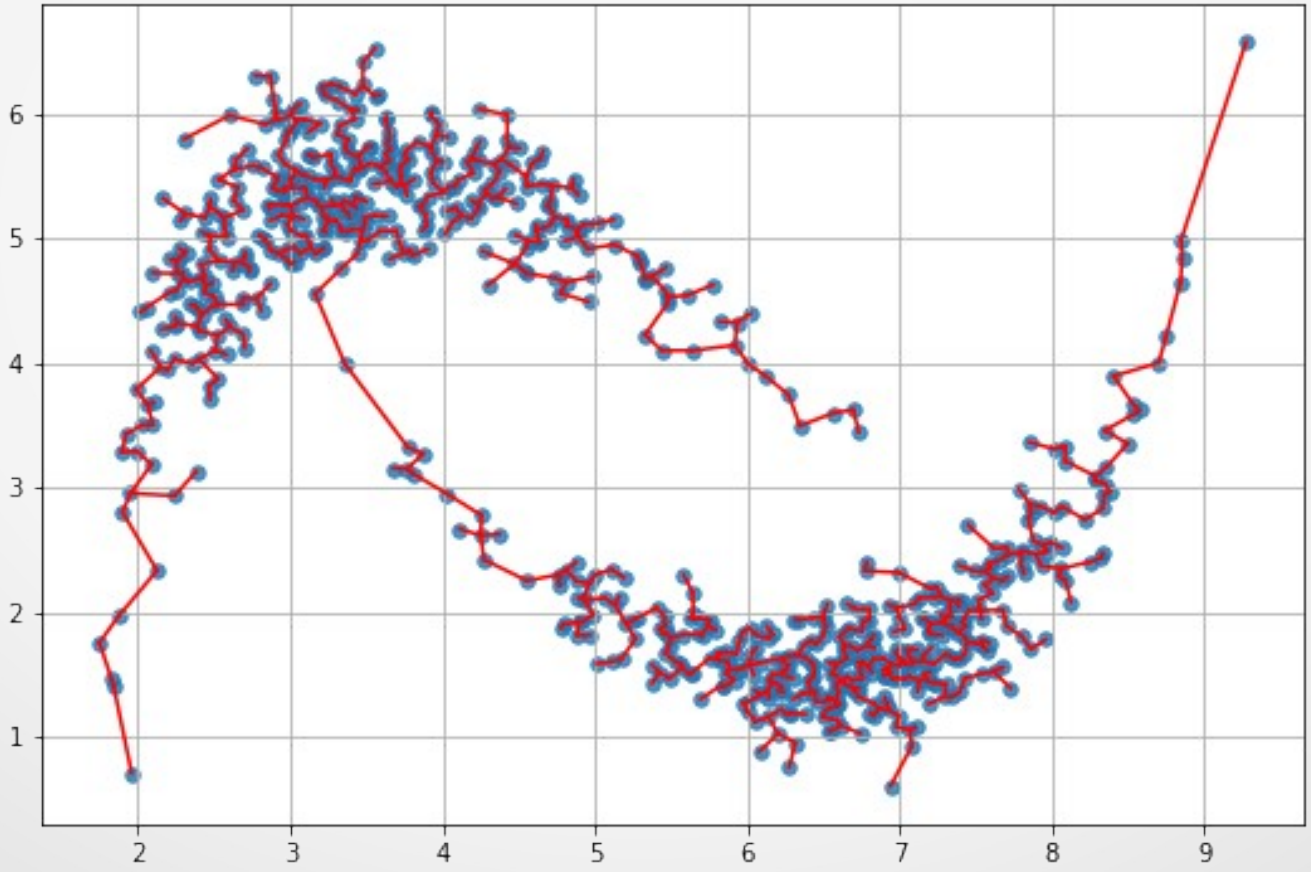

метрические методы : кластеризация

КНП: разрезанный граф

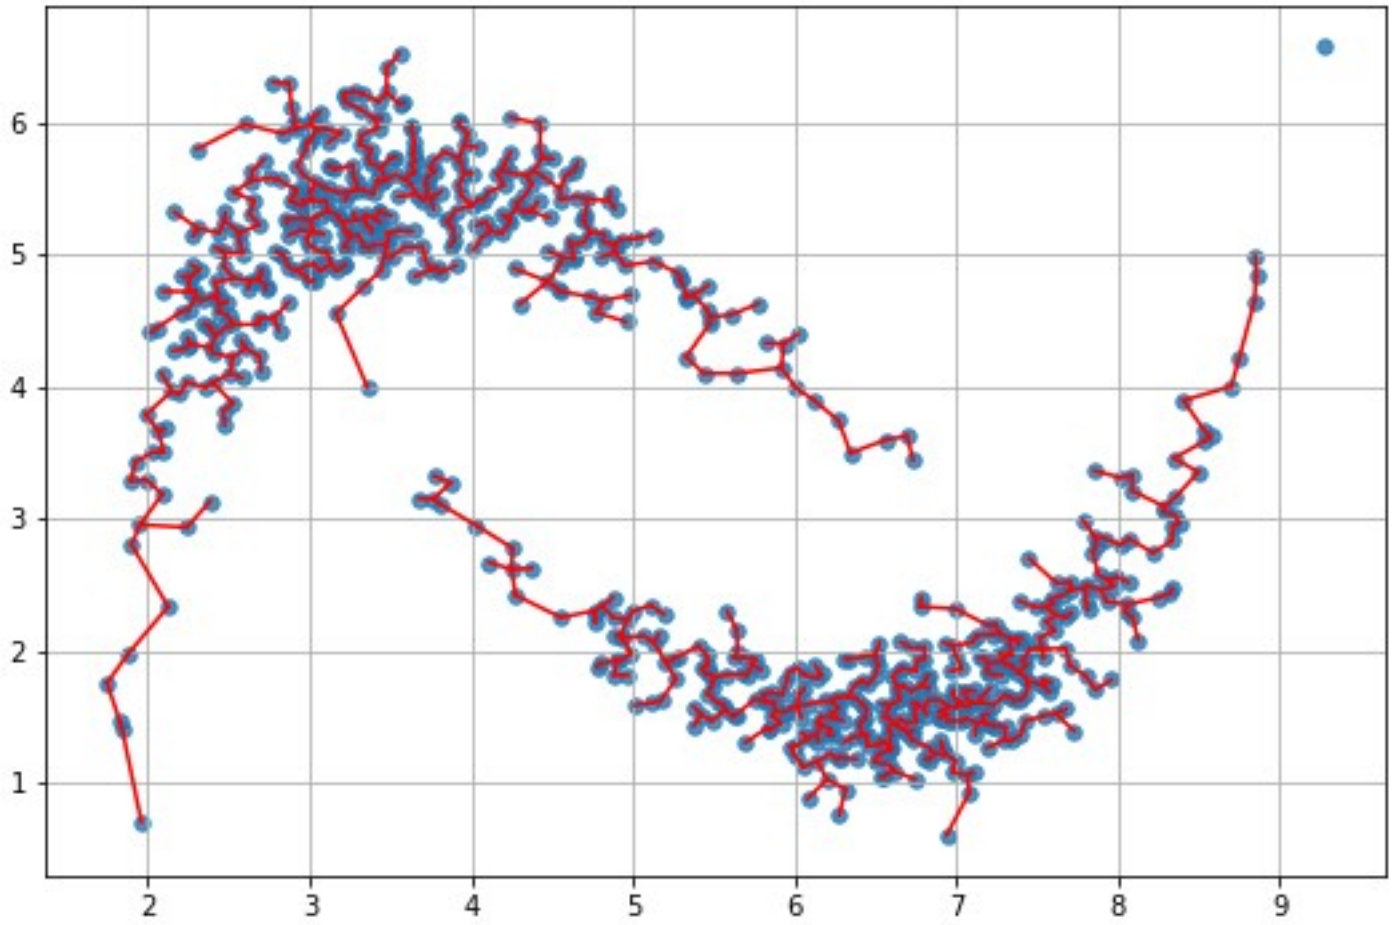

метрические методы : кластеризация

ФорЭл + КНП

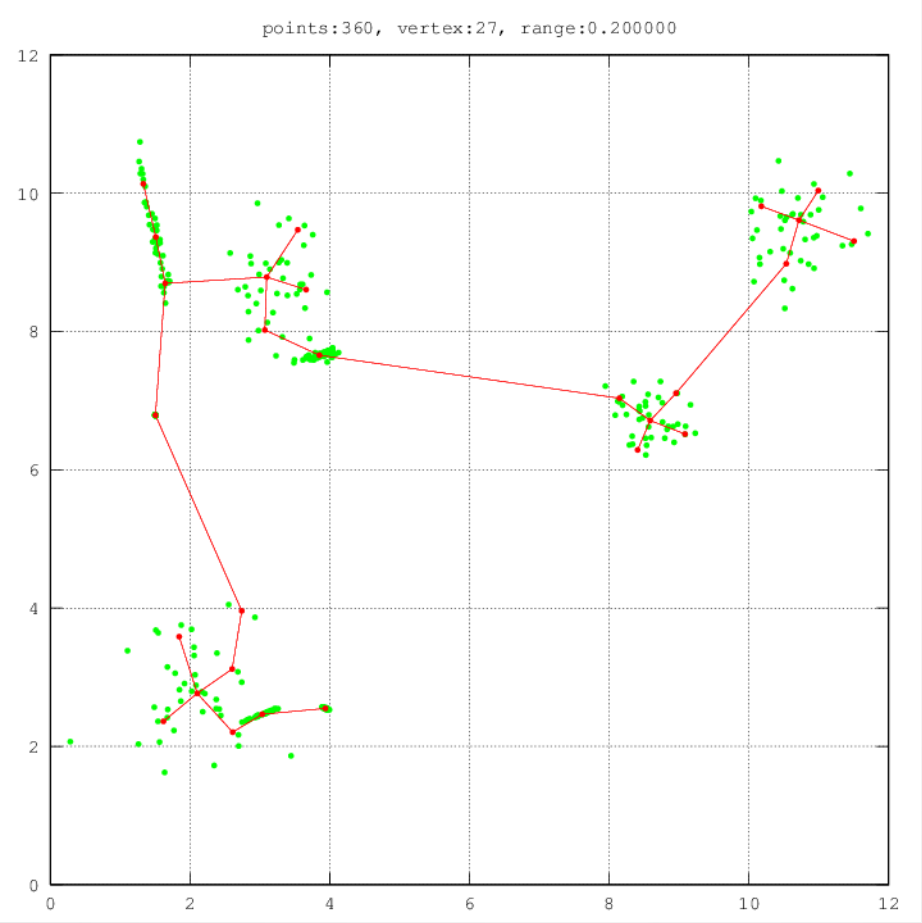

метрические методы : кластеризация

метод DBSCAN

фиксируем размер окрестности точки

минимальное количество объектов в кластере

точки делим на корневые, граничные и шум

кластеризация

метод DBSCAN

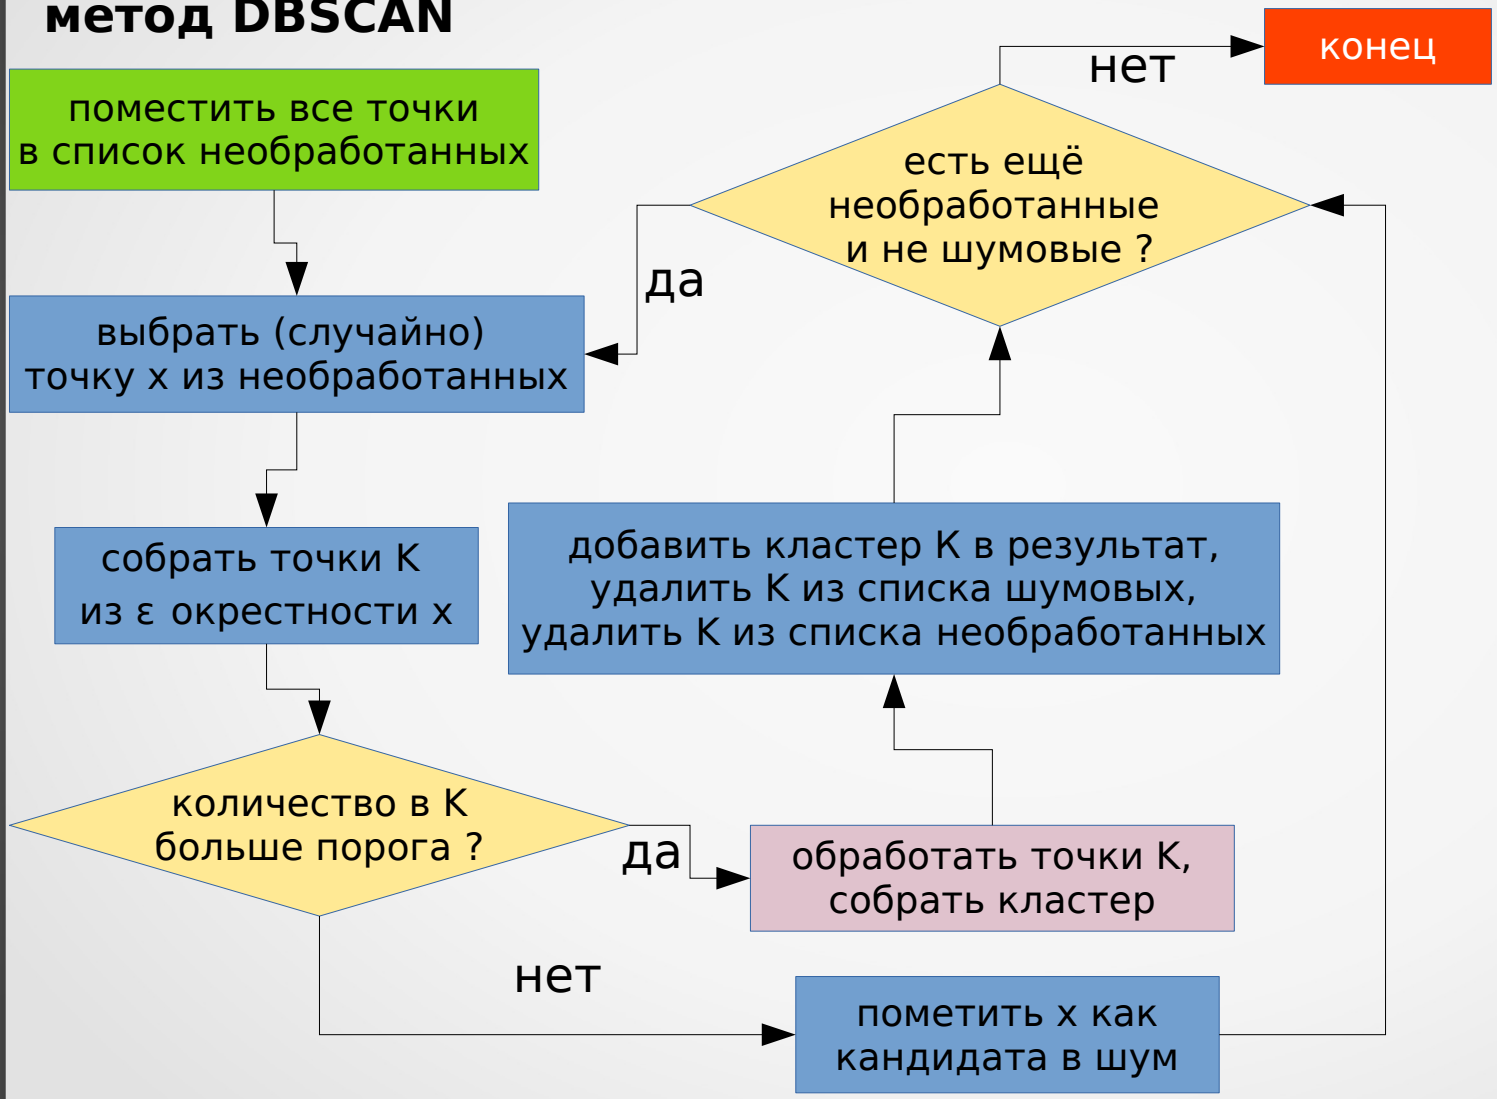

метрические методы : кластеризация

метод DBSCAN

метрические методы : кластеризация

метод DBSCAN - результат

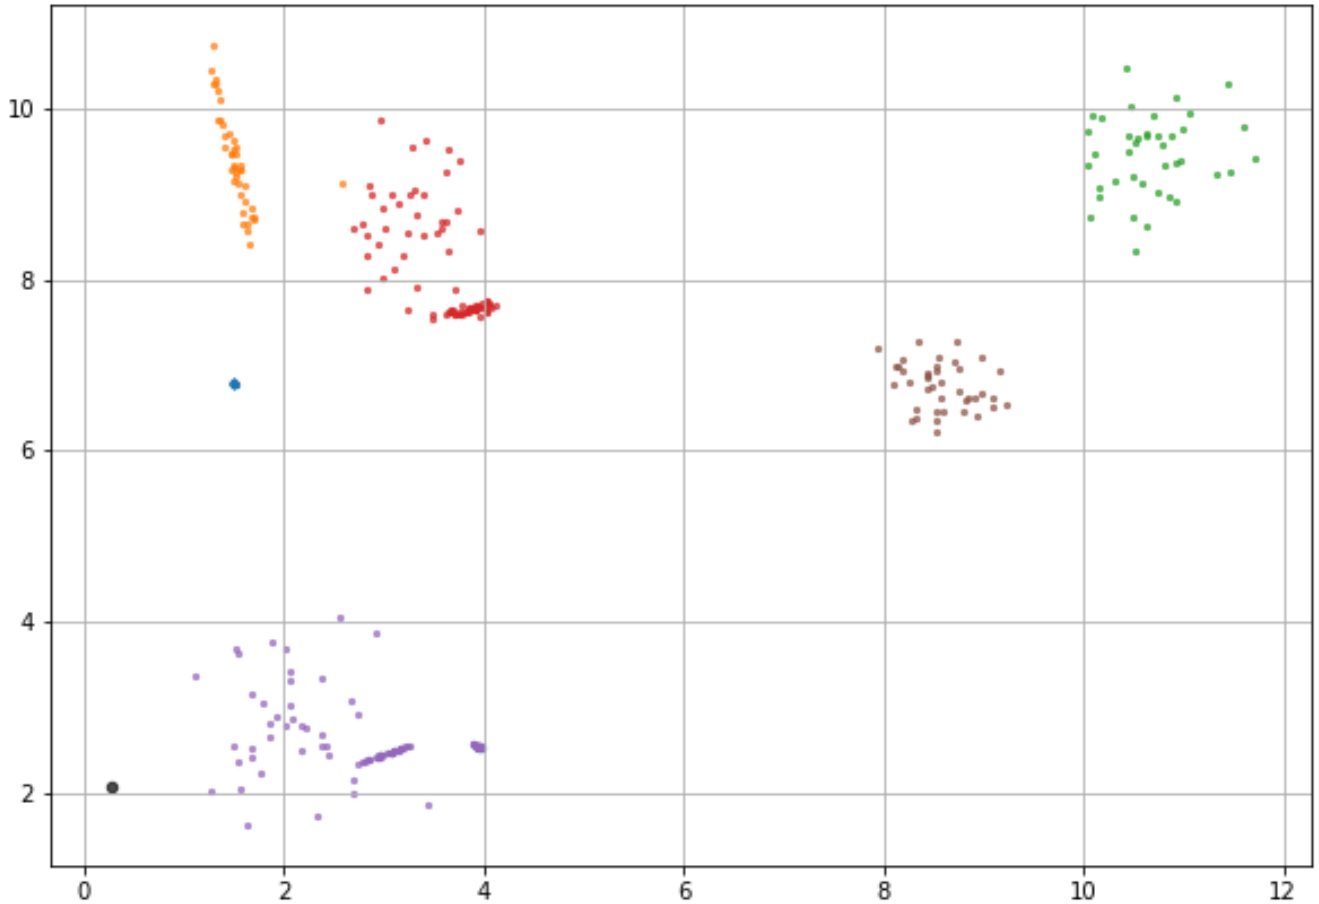

метрические методы : кластеризация

иерархическая кластеризация

Дивизивная (англ. Divisive) - деления более крупных кластеров, создаём дерево от вершины к листьям.

Агломеративная (Agglomerative) - объединение мелких кластеров, создаём дерево от листьев к вершине.

идея - последовательное объединение близких групп объектов

вход: данные
выход: история объединения групп в виде дерева (дендрограмма)

нужен метод оценки расстояний между множествами точек

метрические методы : кластеризация

иерархическая кластеризация

идея - последовательное объединение близких групп объектов

вход: данные
выход: история объединения групп в виде дерева (дендрограмма)

нужен метод оценки расстояний между множествами точек

- расстояние между центрами множеств
- наибольшее расстояние среди всех точек множеств
- наименьшее расстояние между всеми точками множеств
- среднее расстояние между всеми точками множеств

метрические методы : кластеризация

иерархическая кластеризация

последовательное объединение близких групп объектов

метод оценки расстояний между множествами точек

<u>расстояние Уорда</u>

$$\rho_{ward}(W,S)=\frac{|W|\cdot|S|}{|W|+|S|}\cdot\rho\left(\frac{\sum_{w\in W} w}{|W|},\frac{\sum_{s\in S} s}{|S|}\right)$$

метрические методы : кластеризация

иерархическая кластеризация: базовый алгоритм

последовательное объединение близких групп объектов

метрические методы : кластеризация

иерархическая кластеризация: базовый алгоритм

последовательное объединение близких групп объектов

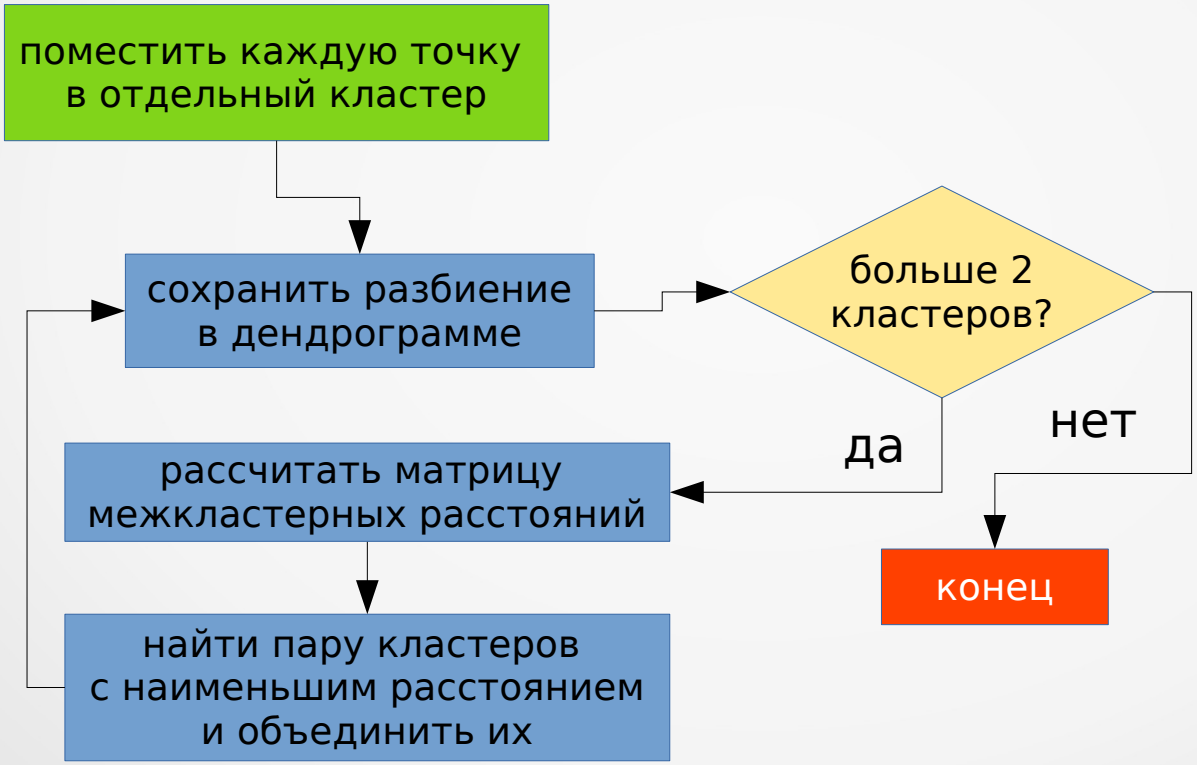

метрические методы : кластеризация

иерархическая кластеризация: регулировка глубины

последовательное объединение близких групп объектов

введём параметр - порог межкластерного расстояния δ

метрические методы : кластеризация

иерархическая кластеризация: регулировка глубины

последовательное объединение близких групп объектов

введём параметр - порог межкластерного расстояния δ

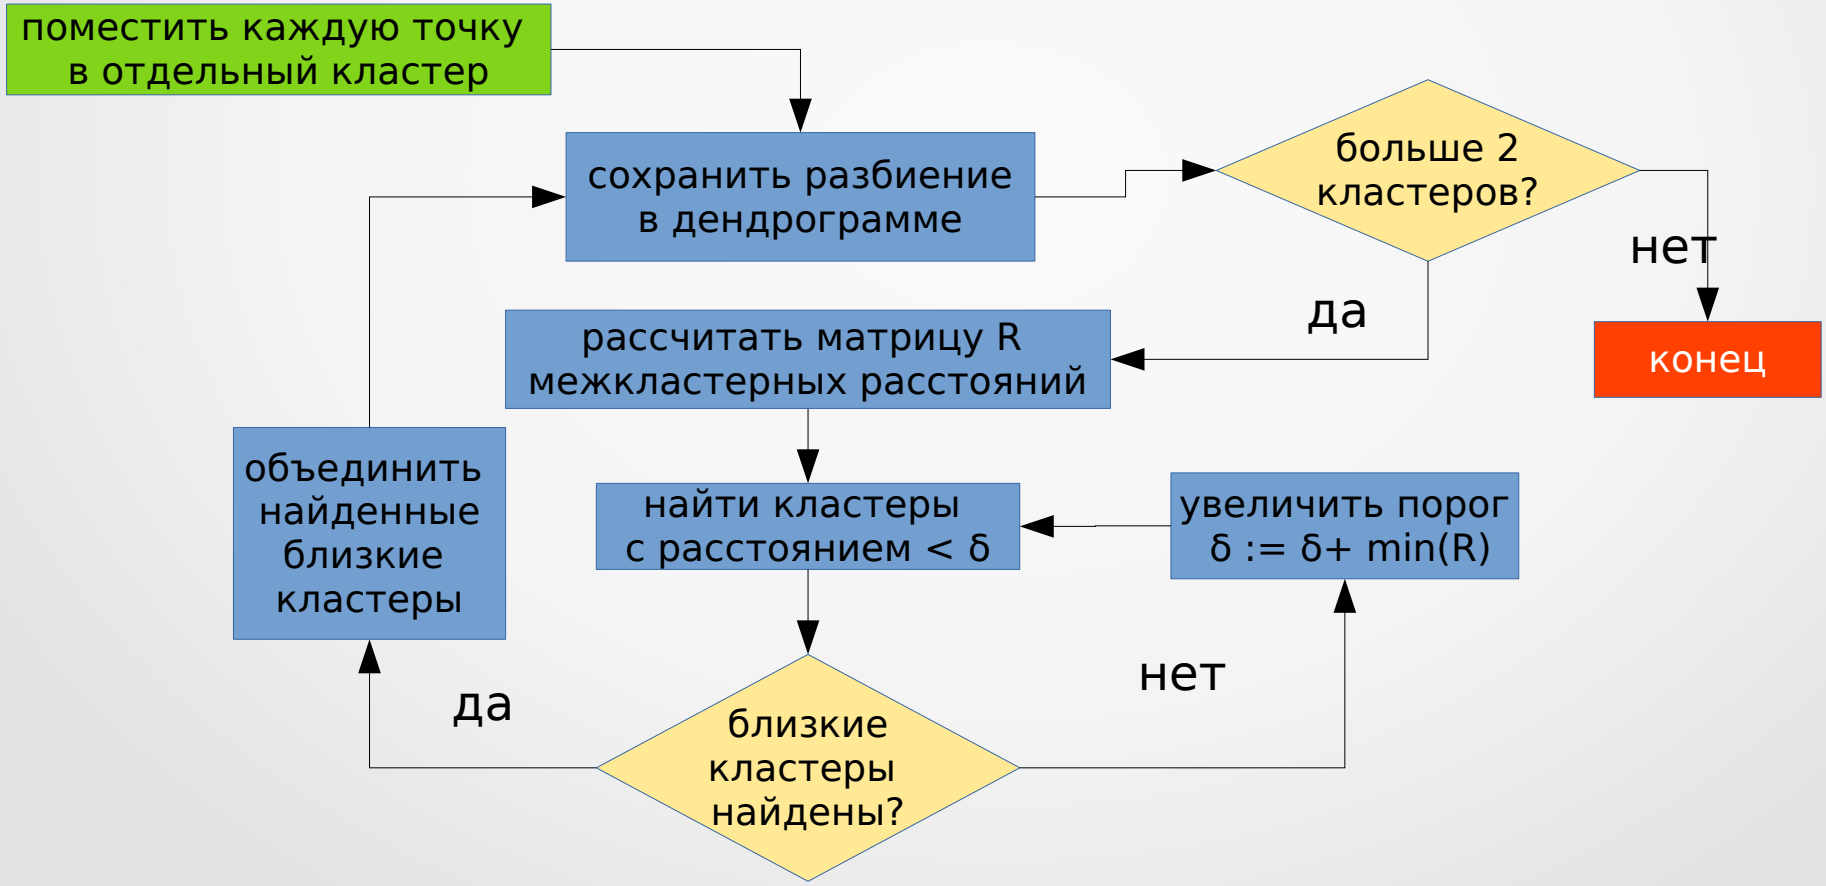

метрические методы : кластеризация

иерархическая кластеризация
последовательное объединение близких групп объектов

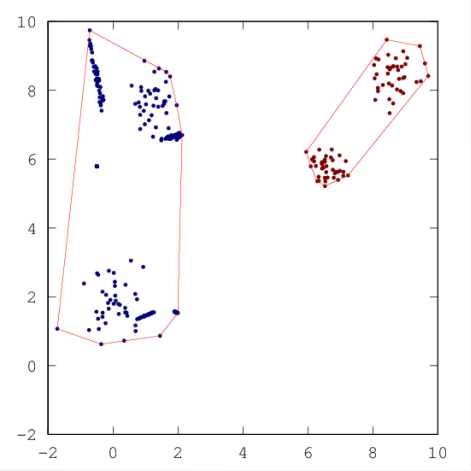

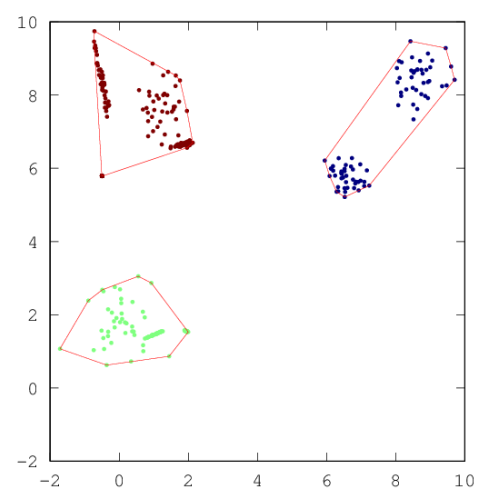

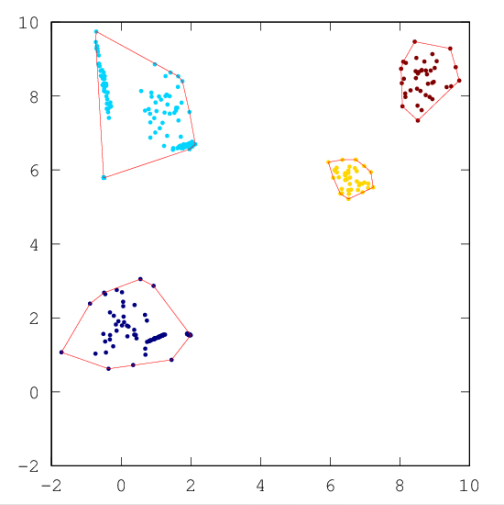

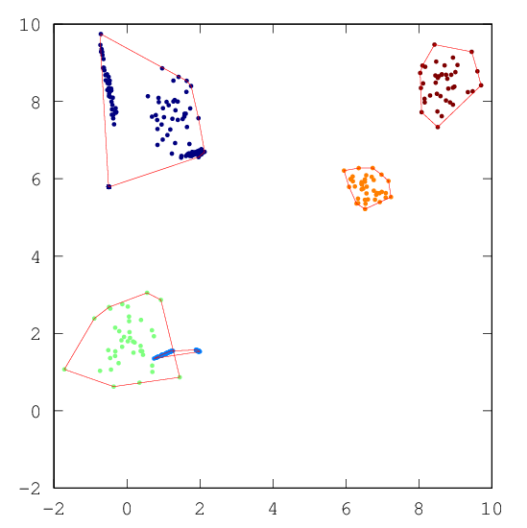

вершина дендрограммы
в 67 слоёв

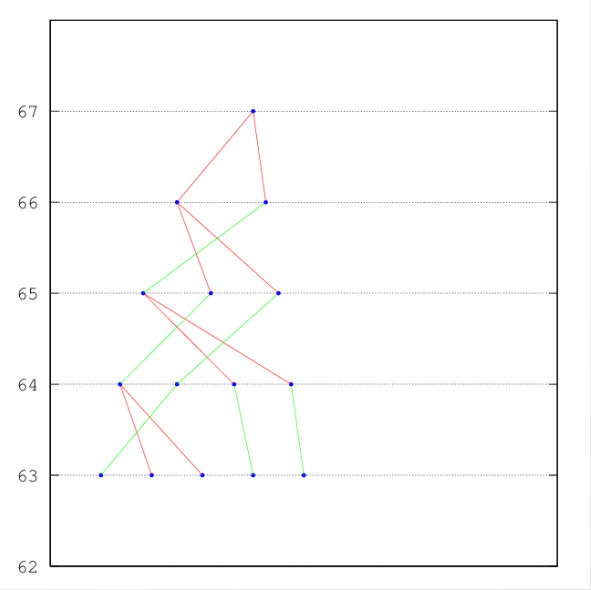

метрические методы : кластеризация

пример - автоматический агрегатор новостей

КЛАСТЕР 1:

Около 18 тысяч человек покинули подконтрольные боевикам районы Алеппо За минувшие сутки из подконтрольных боевикам районов сирийского города Алеппо было выведено около 17,971 тысячи жителей, в их числе 7,542 тысячи детей. Об этом в субботу, 10 декабря, сообщает ТАСС со ссылкой на российский Центр примирения враждующих сторон в Арабской Республике.

Битва за Алеппо: повстанцы просят дать им вывезти раненых Сирийские повстанцы просят о пятидневном перемирии, чтобы эвакуировать раненых из районов в восточной части Алеппо, после того как они вывели все свои отряды из исторического центра — Старого города.

КЛАСТЕР 2:

Финальная распродажа! Chery Tiggo от 19990 руб (199,9 млн)
«Китайские автомобили» объявляют финальную распродажу популярных кроссоверов Chery Tiggo FL! На автомобили в максимальной комплектации установлена специальная цена 19 990 рублей (199,9 млн). Количество автомобилей ограничено!

Не успели купить новый автомобиль в «черную пятницу»? Не нашли ничего подходящего в дилерских автосалонах? Не беда: автосалон «Китайские автомобили» объявляет «черные субботы»! «Черная суббота» — это не шестой трудовой день в советской стране, а желанный праздник для покупателей новеньких авто!

Литература

Борисов Е.С. Методы машинного обучения. 2026
https://github.com/mechanoid5/ml_lectorium_2026_I

Борисов Е.С. Методы обработки текстов на естественном языке. 2026
https://github.com/mechanoid5/ml_nlp_2026_I

Константин Воронцов - Машинное обучение. ШАД Яндекс
https://www.youtube.com/playlist?list=PLJOzdkh8T5kp99tGTEFjH_b9zqEQiiBtC

К.В. Воронцов Машинное обучение. курс лекций. Кластеризация и частичное обучение
https://www.youtube.com/watch?v=oWRmzf9eI-c

Константин Воронцов Машинное_обучение. курс_лекций.
http://www.machinelearning.ru/wiki/index.php?title=Машинное_обучение_(курс_лекций,_К.В.Воронцов)