

Грамматики и синтаксический анализ

Евгений Борисов

Синтаксический анализ

Уровни сложности при автоматической обработке текстов

Прагматика (Дискурс) - смысловые контексты

Семантика - смыслы последовательностей слов

Синтаксис - последовательности слов

Лексика (Морфология) - отдельные слова / словосочетания

Синтаксический анализ

Уровни сложности при автоматической обработке текстов

Прагматика (Дискурс) - смысловые контексты

Семантика - смыслы последовательностей слов

Синтаксис - последовательности слов

Лексика (Морфология) - отдельные слова / словосочетания

Синтаксический анализ

Задача автоматического синтаксического разбора

Применение:


- машинный перевод
- извлечение информации

Синтаксический анализ


Грамматика — способ описания языка

- грамматика зависимостей
- грамматика составляющих

грамматика составляющих




грамматика зависимостей



Образец разбора предложения



Это предложение – **повествовательное, невосклицательное**. Основа предложения – **розы** (подлежащее) **расцвели** (сказуемое). В предложении есть второстепенные члены, поэтому оно **распространённое**. Розы (какие?) **красные и белые** – однородные определения, произносятся с интонацией перечисления. Расцвели (где?) **в саду** – обстоятельство.



Грамматика составляющих

Синтаксический анализ

Грамматика составляющих (Constituency grammar)

предложение (П; sentence, S).



именная группа (группа существительного, ИГ; noun phrase, NP) — возглавляется существительным;

группа прилагательного (ГПрил; adjectival phrase, AP) — возглавляется прилагательным;

наречная группа (НарГ; adverbial phrase, AdvP) — возглавляется наречием;

предложная группа (ПрГ; prepositional phrase, PP) — возглавляется предлогом;

глагольная группа (ГГ; verb phrase, VP) — возглавляется глаголом;



Синтаксический анализ

грамматика составляющих (constituency grammar)

— разметка (вложенных) групп

именная группа (группа существительного, ИГ; англ. noun phrase, NP) — возглавляется существительным;


группа прилагательного (ГПрил; adjectival phrase, AP) — возглавляется прилагательным;

наречная группа (НарГ; adverbial phrase, AdvP) — возглавляется наречием;

предложная группа (ПрГ; prepositional phrase, PP) — возглавляется предлогом;

глагольная группа (ГГ; verb phrase, VP) — возглавляется глаголом;

предложение (П; sentence, S).



[s[NP Эти школьники] скоро[VP будут писать][NP диктант[PP по [NP русскому языку]]]]

Синтаксический анализ

Формальная грамматика - способ описания языка

$$G=(N, \Sigma, R, s); V=N \cup \Sigma$$

N — множество (алфавит) нетерминальных символов (синтаксические переменные или понятия)

Σ - множество (алфавит) терминальных символов (не пересекается с N)

V - словарь грамматики G

s - начальный нетерминал (принадлежит алфавиту нетерминалов N)

R - конечное множество правил вывода (продукции), вида $A \rightarrow b$, где A, b — последовательности символов из алфавита V грамматики G

Нетерминальные символы

- объекты, обозначающие какую-либо сущность языка (предложение, формула и т.д.).

Терминальные символы

- объекты непосредственно присутствующие в языке.

Синтаксический анализ

Форма Бэкуса-Наура (БНФ) - способ представления КС-грамматик

Lex/Yacc калькулятор:

```
%token INTEGER
```

```
expr: INTEGER  
    | "-" expr  
    | "(" expr ")"  
    | expr "-" expr  
    | expr "+" expr  
    | expr "*" expr  
    | expr "/" expr
```


expr — нетерминальный символ (объект, обозначающий сущность языка)

- + () * / число — терминальные символы (объекты непосредственно присутствующие в языке)

(пример описывает только INT)

Синтаксический анализ

БНФ и диаграммы Вирта



Синтаксический анализ

классификация формальных грамматик по Хомскому


неограниченные

$R : V \rightarrow \beta$

V — любая непустая последовательность из V содержащая нетерминалы

β — любая (в т.ч. пустая) последовательность из V

$$G = (N, \Sigma, R, s); V = N \cup \Sigma$$



Avram Noam Chomsky

Синтаксический анализ

классификация формальных грамматик по Хомскому

неограниченные

$$R : V \rightarrow \beta$$

V — любая непустая последовательность из V содержащая нетерминалы

β — любая (в т.ч. пустая) последовательность из V

контекстно-зависимые


$$R : \alpha A \beta \rightarrow \alpha \gamma \beta$$

A — нетерминал из N

α, β — любые (в т.ч. пустые) последовательности из V

γ — любая непустая последовательность из V

$$G = (N, \Sigma, R, s); V = N \cup \Sigma$$



Avram Noam Chomsky

Синтаксический анализ

классификация формальных грамматик по Хомскому

неограниченные

$$R : \alpha \rightarrow \beta$$

α — любая непустая последовательность из V содержащая нетерминалы
 β — любая (в т.ч. пустая) последовательность из V

контекстно-зависимые

$$R : \alpha A \beta \rightarrow \alpha \gamma \beta$$

A — нетерминал из N
 α, β — любые (в т.ч. пустые) последовательности из V
 γ — любая непустая последовательность из V


контекстно-свободные

$$R : A \rightarrow \beta$$

A — нетерминал из N
 β — любая (в т.ч. пустая) последовательность из V

применяются для описания компьютерных языков

$$G = (N, \Sigma, R, s); V = N \cup \Sigma$$



Avram Noam Chomsky

Синтаксический анализ

классификация формальных грамматик по Хомскому

неограниченные

$$R : V \rightarrow \beta$$

V — любая непустая последовательность из V содержащая нетерминалы

β — любая (в т.ч. пустая) последовательность из V

$$G = (N, \Sigma, R, s); V = N \cup \Sigma$$


контекстно-зависимые

$$R : \alpha A \beta \rightarrow \alpha \gamma \beta$$

A — нетерминал из N

α, β — любые (в т.ч. пустые) последовательности из V

γ — любая непустая последовательность из V



Avram Noam Chomsky

контекстно-свободные

$$R : A \rightarrow \beta$$

A — нетерминал из N

β — любая (в т.ч. пустая) последовательность из V

применяются для описания компьютерных языков

регулярные

$$R : A \rightarrow A\beta, A \rightarrow \beta \text{ (леворекурсивные)}$$

$$R : A \rightarrow \beta A, A \rightarrow \beta \text{ (праворекурсивные)}$$

A — нетерминал из N

β — последовательность (в т.ч. пустая) терминалов из Σ

применяются для описания простых конструкций

Синтаксический анализ

Нормальная форма грамматики по Хомскому (CNF)

продукции имеют вид: $A \rightarrow BC$, $A \rightarrow \alpha$, $s \rightarrow \epsilon$,

где

A, B, C – нетерминалы (B и C не могут являться начальными символами),

α – терминальный символ,

s – начальный символ,

ϵ – пустая строка (грамматика может порождать пустую строку)

Эквивалентность грамматик

- сильная (совпадает язык и дерево разбора)
- слабая (совпадает язык, деревья разбора могут отличаться)

Теорема:

любая КС-грамматика может быть преобразована в эквивалентную CNF-грамматику.

Синтаксический анализ

Методы синтаксического разбора


- рекурсивный спуск (top-down parsing)
- восходящий анализ (bottom-up parsing)
- алгоритм Кока-Янгера-Касами (CKY parsing)
- алгоритм Эрли (Earley parser)

...

Синтаксический анализ

S → NP VP
S → Aux NP VP
S → VP
NP → Pronoun
NP → Proper-Noun
NP → Det Nominal
Nominal → Noun
Nominal → Nominal Noun
Nominal → Nominal PP
VP → Verb
VP → Verb NP
VP → Verb NP PP
VP → Verb PP
VP → VP PP
PP → Preposition NP



Det → that | this | a
Noun → book | flight | meal | money
Verb → book | include | prefer
Pronoun → I | she | me
Proper-Noun → Houston | TWA
Aux → does
Preposition → from | to | on | near | through



Синтаксический анализ

Анализ рекурсивным спуском (top-down parsing)

правила формальной грамматики раскрываются, начиная со стартового символа, до получения требуемой последовательности токенов.



Синтаксический анализ

Частичный разбор (группировка, применение группы правил)


Применяется для извлечения именованных сущностей

- Partial parsing, Shallow parsing
- Chunking, фрагментирование
 - [_{NP} The morning flight][_{PP} from][_{NP} Denver][_{VP} has arrived]
 - [_{NP} The morning flight] from [_{NP} Denver] has arrived

Синтаксический анализ

Группировка на основе машинного обучения

- Классы BIO (begin, inside, outside)
- Тренировочное множество - Treebank



Признаки: *The*, *DT*, *B_NP*, *morning*, *NN*, *I_NP*, *flight*, *NN*, *from*, *IN*, *Denver*, *NNP*

Синтаксический анализ

Статистические КС-грамматики

$$G=(N, \Sigma, R, s); V=N \cup \Sigma$$

N — множество (алфавит) нетерминальных символов (синтаксические переменные или понятия)

Σ - множество (алфавит) терминальных символов (не пересекается с N)

V - словарь грамматики G

s - начальный нетерминал (принадлежит алфавиту нетерминалов N)

R - конечное множество правил вывода (продукции),

вида $A \rightarrow \beta[p]$

где

A — нетерминал из N

β — последовательности символов из алфавита V грамматики G

p — **вероятность правила** $P(\beta|A)$ (сумма вероятностей всех правил вида $A \rightarrow *$ равна 1)

Нетерминальные символы

- объекты, обозначающие какую-либо сущность языка (предложение, формула и т.д.).

Терминальные символы

- объекты непосредственно присутствующие в языке.

Синтаксический анализ

Статистические КС-грамматики

Грамматика	Вероятность	Лексикон
S → NP VP	0.8	Det → the a that this
S → Aux NP VP	0.1 +	0.6 0.2 0.1 0.1
S → VP	0.1	Noun → book flight meal money
NP → Pronoun	0.2	0.1 0.5 0.2 0.2
NP → Proper-Noun	0.2 +	Verb → book include prefer
NP → Det Nominal	0.6	0.5 0.2 0.3
Nominal → Noun	0.3	Pronoun → I he she me
Nominal → Nominal Noun	0.2 +	0.5 0.1 0.1 0.3
Nominal → Nominal PP	0.5	Proper-Noun → Houston NWA
VP → Verb	0.2	0.8 0.2
VP → Verb NP	0.5 +	Aux → does
VP → VP PP	0.3	1.0
PP → Prep NP	1.0	Prep → from to on near through
		0.25 0.25 0.1 0.2 0.2

Синтаксический анализ

Статистические КС-грамматики

Разрешение многозначности

- Вероятность разбора

$$P(T, S) = \prod_{i=1}^n P(RHS_i | LHS_i)$$

- Вероятность $P(T, S) = P(T)P(S|T) = P(T)$

- Выбор наиболее вероятного дерева разбора $\hat{T}(S) = \arg \max_T P(T|S)$

$$\hat{T}(S) = \arg \max_T \frac{P(T, S)}{P(S)}$$



$$\hat{T}(S) = \arg \max_T P(T, S)$$

$$\hat{T}(S) = \arg \max_T P(T)$$

Синтаксический анализ

Статистические КС-грамматики

Разрешение многозначности



$$P(T\text{-left}) = .05 \cdot .20 \cdot .20 \cdot .20 \cdot .75 \cdot .30 \cdot .60 \cdot .10 \cdot .40 = 2.2 \cdot 10^{-6}$$

$$P(T\text{-right}) = .05 \cdot .10 \cdot .20 \cdot .15 \cdot .75 \cdot .75 \cdot .30 \cdot .60 \cdot .10 \cdot .40 = 6.1 \cdot 10^{-7}$$

Синтаксический анализ

Статистические КС-грамматики

Обучение КС

- Вычисление вероятности на основе банка деревьев


$$P(\alpha \rightarrow \beta | \alpha) = \frac{\text{Count}(\alpha \rightarrow \beta)}{\sum_{\gamma} \text{Count}(\alpha \rightarrow \gamma)} = \frac{\text{Count}(\alpha \rightarrow \beta)}{\text{Count}(\alpha)}$$

- Вывод без тренировочного множества (ЕМ)
 - На основе множества предложений построить множество наиболее вероятных синтаксических разборов
 - Обновить значения вероятностей на основе полученных данных
 - (Manning and Schutze 1999)

Синтаксический анализ

Оценка качества алгоритма

- Метрика PARSEVAL: пусть P - дерево разбора, созданное алгоритмом, T - дерево разбора, созданное экспертами
 - Точность = $(\# \text{ правильных компонент в } P) / (\# \text{ компонент в } T)$
 - Полнота = $(\# \text{ правильных компонент в } P) / (\# \text{ компонент в } P)$
 - F-мера = $2PR / (P + R)$
- Современные алгоритмы показывают точность и полноту более 90%



Граммати́ка зави́симостей


Синтаксический анализ

Грамматика зависимостей (Dependency grammar)

Главные члены предложения

Подлежащее — предмет. кто? что?

Сказуемое — что делать? что сделать? каков?



Образец разбора предложения

Где? Какие? Какие?

В саду расцвели красные и белые розы.



Это предложение – **повествовательное, невосклицательное**. Основная часть предложения – **розы** (подлежащее) **расцвели** (сказуемое). В предложении есть второстепенные члены, поэтому оно **распространённое**. **Розы** (какие?) **красные и белые** – однородные определения, произносятся с интонацией перечисления. **Расцвели** (где?) **в саду** – обстоятельство.

Второстепенные члены предложения

Определение — признак предмета.
какой? чей? который?

Обстоятельство — время, место, способ действия.
где? когда? куда? откуда? почему? зачем? как?

Дополнение — предмет. кого? чего? кому? чему?
кого? что? кем? чем? о ком? о чём?

Синтаксический анализ

Разбор в грамматику зависимостей

- Dependency parser
 - Malt parser (2006)
 - Stanford Neural Network Dependency Parser (2014)

строим ориентированный граф зависимостей
на упорядоченном множестве слов

Синтаксический анализ



Разбор в грамматику зависимостей

- Остановка
 - стек содержит один узел $ROOT$
 - и буфер пуст
- На каждой итерации происходит выбор одного из трех правил (для выбора используется классификатор)
 - $LEFT-ARC(label)$: добавление дуги $s_1 \rightarrow s_2$ с меткой $label$ и удаление s_2 из стека. Предусловие: $|s| \geq 2$
 - $RIGHT-ARC(label)$: добавление дуги $s_2 \rightarrow s_1$ с меткой $label$ и удаление s_1 из стека. Предусловие: $|s| \geq 2$
 - $SHIFT$: перенос b_1 из буфера в стек. $|b| \geq 1$
- Итеративный алгоритм разбора предложения $w_1, w_2, \dots, w_n$
- Состояние парсера $c = (s, b, A)$:
 - стек $s = [Root]$
 - буфер $b = [w_1, w_2, \dots, w_n]$
 - множество дуг зависимостей $A = \emptyset$

используем ML классификатор для выбора правила на каждом шаге

Синтаксический анализ

Пример



Transition	Stack	Buffer	A
	[ROOT]	[He has good control .]	∅
SHIFT	[ROOT He]	[has good control .]	
SHIFT	[ROOT He has]	[good control .]	
LEFT-ARC (nsubj)	[ROOT has]	[good control .]	A ∪ nsubj(has, He)
SHIFT	[ROOT has good]	[control .]	
SHIFT	[ROOT has good control]	[.]	
LEFT-ARC (amod)	[ROOT has control]	[.]	A ∪ amod(control, good)
RIGHT-ARC (dobj)	[ROOT has]	[.]	A ∪ dobj(has, control)
...	...	...	...
RIGHT-ARC (root)	[ROOT]	[.]	A ∪ root(ROOT, has)

Синтаксический анализ

Литература

Борисов Е.С. Методы машинного обучения. 2025
https://github.com/mechanoid5/ml_lectorium_2025_I

Борисов Е.С. Методы обработки текстов на естественном языке. 2025
https://github.com/mechanoid5/ml_nlp_2025_I

Турдаков Д.Ю. Основы обработки текстов. Лекция 7.
Формальные грамматики и синтаксический анализ. ИСП РАН, 2017
<https://www.youtube.com/watch?v=TkMtUm-D6aE>

Steven Bird, Ewan Klein, and Edward Loper Analyzing Text with the Natural Language Toolkit
<https://www.nltk.org/book/>

D.Jurafsky,J.H.Martin Speech and Language Processing. third edition, 2020

А. Ахо, Дж. Ульман. Теория синтаксического анализа, перевода и компиляции. М.: Мир, 1978.

Д.Кук, Г.Бейз Компьютерная математика - Москва: Наука, 1990

В.С.Проценко, П.Й.Чаленко Элементы компиляции - Киев: УМК ВО, 1988

Е.С.Борисов Методы и средства построения грамматических анализаторов.
<http://mechanoid.su/programming-grammar-analysis.html>