


Нейросетевые языковые модели Transformer

Евгений Борисов

Нейросетевые языковые модели




Нейросетевые языковые модели

Схема Encoder-Decoder прямого распространения

Модель Transformer и механизм Self-Attention

Attention Is All You Need (2017) <https://arxiv.org/abs/1706.03762>



токенизация BPE (Byte Pair Encoding)

Sennrich R., et al. Neural machine translation of rare words with subword units- 2015.


Нейросетевые языковые модели

Transformer: Энкодер

- блок внимания MHSA
- skip connection, normalization
- сеть прямого распространения

все слова подаём в модель одновременно,
они обрабатываются совместно,

схема вычислений хорошо распараллеливается




Нейросетевые языковые модели

Transformer: Encoder : Self-Attention

query - откуда смотрим (из какого слова)

key - куда смотрим (на какое слово)

value - смысл (условно) слова



Вход:	Осенью	часто	идет	дождь
Векторы:	x_1	x_2	x_3	x_4
Запросы:	q_1	q_2	q_3	q_4
Ключи:	k_1	k_2	k_3	k_4
Оценки:	$q_3 k_1 / \sqrt{d}$	$q_3 k_2 / \sqrt{d}$	$q_3 k_3 / \sqrt{d}$	$q_3 k_4 / \sqrt{d}$
softmax:	0.1	0.08	0.7	0.12
Значения:	v_1	v_2	v_3	v_4
Сумма:	z_1	z_2	z_3	z_4

Осенью	часто	идет	дождь
x_1	x_2	x_3	x_4
$Q = X * W^Q$			
$K = X * W^K$			
$V = X * W^V$			
$Z = \text{softmax}\left(\frac{QK^T}{\sqrt{d_K}}\right)V$			
z_1	z_2	z_3	z_4



все слова подаём в модель одновременно,
они обрабатываются совместно,
схема вычислений хорошо распараллеливается

Нейросетевые языковые модели

Transformer: Encoder : Multi-Head-Self-Attention

Используем параллельно несколько блоков Self-Attention с разными весами

Результаты агрегируются в размер входа X для стекирования блоков энкодера



Нейросетевые языковые модели

Transformer: Encoder : Multi-Head-Self-Attention

1) This is our input sentence*


2) We embed each word*

3) Split into 8 heads.
We multiply X with weight matrices

4) Calculate attention using the resulting $Q/K/V$ matrices

5) Concatenate the resulting Z matrices, then multiply with weight matrix W^O to produce the output of the layer

Thinking
Machines




Нейросетевые языковые модели

Transformer: Encoder

Проблема: не учитывается порядок слов

Решение: positional encoding



Нейросетевые языковые модели

Transformer: Encoder : Positional encoding

Необходимо обозначить позицию слова, выполняя условия


- уникальность для каждого слова
- не зависит от длины предложения
- детерминирован (не стохастический)

$$\vec{p}_t^{(i)} = f(t)^{(i)} = \begin{cases} \sin(\omega_k t), & \text{if } i = 2k \\ \cos(\omega_k t), & \text{if } i = 2k + 1 \end{cases}$$

$$\omega_k = \frac{1}{10000^{2k/d}}$$

$$\vec{p}_t = \begin{bmatrix} \sin(\omega_1.t) \\ \cos(\omega_1.t) \\ \sin(\omega_2.t) \\ \cos(\omega_2.t) \\ \vdots \\ \sin(\omega_{d/2}.t) \\ \cos(\omega_{d/2}.t) \end{bmatrix}_{d \times 1}$$

t – номер слова в строке
 d – размерность входа модели
 k – номер элемента в векторе PE





PE – не обучается вместе с моделью,
но вычисляется по формуле

длина последовательности ограничена

Нейросетевые языковые модели

Transformer: Decoder

авторегрессионная модель - выход подаём на вход



- encoder-decoder attention, используем $[K, V]$ из последнего блока encoder

- masked MHA
при расчёте self-attention используем только левый контекст

Нейросетевые языковые модели

Transformer: Decoder : Masked Multi-Head-Self-Attention

в процессе обучения модели,
при расчёте self-attention используем только левый контекст

Вход:	Осенью	часто	идет	ДОЖДЬ
Векторы:	x_1	x_2	x_3	x_4
Запросы:	q_1	q_2	q_3	q_4
Ключи:	k_1	k_2	k_3	k_4
Оценки:	$q_3 k_1 / \sqrt{d}$	$q_3 k_2 / \sqrt{d}$	$q_3 k_3 / \sqrt{d}$	$-\infty$
softmax:	0.14	0.12	0.74	0
Значения:	v_1	v_2	v_3	
Сумма:	z_1	z_2	z_3	z_4



Осенью	часто	идет	ДОЖДЬ
x_1	x_2	x_3	x_4
$Q = X * W^Q$			
$K = X * W^K$			
$V = X * W^V$			
$Z = \text{softmax}\left(\frac{QK^T}{\sqrt{d_K}}\right)V$			
z_1	z_2	z_3	z_4

Нейросетевые языковые модели

Transformer: Decoder : Encoder-Decoder Attention

используем [K,V] берём из последнего блока encoder

похоже на Attention из рекуррентных SEQ2SEQ



Нейросетевые языковые модели



Схема Encoder-Decoder прямого распространения

Модель Transformer и механизм Self-Attention

Attention Is All You Need (2017) <https://arxiv.org/abs/1706.03762>

токенизация BPE (Byte Pair Encoding)

Sennrich R., et al. Neural machine translation of rare words with subword units- 2015.



Литература

Литература

Борисов Е.С. Методы машинного обучения. 2024
https://github.com/mechanoid5/ml_lectorium_2024_I

Борисов Е.С. Методы обработки текстов на естественном языке. 2024
https://github.com/mechanoid5/ml_nlp_2024_I

Майоров В.Д. Основы обработки текстов. 10. Языковые модели. ИСП РАН, 2021
https://www.youtube.com/watch?v=_8MGdpt4I9M

Тихомиров М.М. Основы обработки текстов. 14. Большие языковые модели. ИСП РАН, 2023
https://www.youtube.com/watch?v=EC6_rMs1vsY

Нейчев Радослав Self-Attention. Transformer overview. Лекторий ФПМИ, 2020
<https://www.youtube.com/watch?v=UETKUIlYE6g>

Jay Alammar Transformer в картинках. (Перевод - Е.Смирнова, С. Шкарин)
<https://habr.com/ru/articles/486358/>

Jay Alammar GPT-2 в картинках. (Перевод - Е.Смирнова, С. Шкарин)
<https://habr.com/ru/articles/490842/>