



Краткое введение в Большие языковые модели

Евгений Борисов

Большие языковые модели

LLM - большая языковая модель, содержит большое количество параметров

GPT-3 (OpenAI, 2020) - 175 миллиардов параметров

LLaMA (Meta AI, 2023) - 7 до 65 миллиардов параметров (140 GB)

LM SYS Chatbot Arena Leaderboard

<https://huggingface.co/spaces/lmsys/chatbot-arena-leaderboard>

Rank ▲	Model ▲	★ Arena Elo ▲	📊 95% CI ▲	📊 Votes ▲	Organization
1	Claude 3 Opus	1253	+5/-5	33250	Anthropic
1	GPT-4-1106-preview	1251	+4/-4	54141	OpenAI
1	GPT-4-0125-preview	1248	+4/-4	34825	OpenAI
4	Bard (Gemini Pro)	1203	+5/-7	12476	Google
4	Claude 3 Sonnet	1198	+5/-5	32761	Anthropic
6	GPT-4-0314	1185	+5/-4	33499	OpenAI
6	Claude 3 Haiku	1179	+5/-5	18776	Anthropic
8	GPT-4-0613	1158	+4/-5	51860	OpenAI
8	Mistral-Large-2402	1157	+5/-4	26734	Mistral
9	Qwen1.5-72B-Chat	1148	+5/-5	20211	Alibaba
10	Claude-1	1146	+6/-6	21908	Anthropic
10	Mistral-Medium	1145	+5/-4	26196	Mistral

Нейросетевые языковые модели



Нейросетевые языковые модели

Модели GPT (Generative Pre-Training)

Radford A. et al. Improving language understanding by generative pre-training. – 2018

Схема обучения модели на основе GPT

- Предобучение на корпусе $\mathcal{U}$ (без учителя)

$$\begin{aligned}h_0 &= UW_e + W_p; \\h_i &= \text{transformer}(h_{i-1}), i = \overline{1, n} \\P(u) &= \text{softmax}(h_n W_e^T)\end{aligned}$$

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

- Донастройка под целевую задачу на корпусе $\mathcal{C}$ (с учителем)

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y)$$

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y | x^1, \dots, x^m)$$


$$L(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C});$$

Нейросетевые языковые модели

Модели GPT (Generative Pre-Training)

Radford A. et al. Improving language understanding by generative pre-training. – 2018

Различные варианты применения GPT



Нейросетевые языковые модели

Модели GPT (Generative Pre-Training)

GPT: Radford A. et al. Improving language understanding by generative pre-training. – 2018
- 12 слоев трансформера



GPT-2: Radford A. et al. Language models are unsupervised multitask learners – 2019
- 48 слоев трансформера
- Больше корпус для обучения (40 GB текста)
- Другая токенизация: BPE по байтам, а не по символам
- передвинут Layer normalization
- изменена инициализация

GPT-3: Brown T. B. et al. Language models are few-shot learners – 2020.
(почти не отличается от GPT-2)
- 96 слоев трансформера
- Еще больше корпус для обучения (570 GB текста)
- Еще больше контекст (2048 токенов)

Большие языковые модели

Тюнинг базовой модели под свою задачу

- прямое дообучение
- частичное дообучение PEFT/LoRA
- RAG (Retrieval-Augmented Generation)



Большие языковые модели

для обучения LLM с нуля требуются большие ресурсы

датасет из текстов 3TB

кластер из 200 GPU

процесс может занимать несколько недель

Большие языковые модели

платные API и предобученные модели в открытом доступе

HuggingFace <https://huggingface.co>


The screenshot displays the Hugging Face website interface. At the top, there is a navigation bar with the Hugging Face logo, a search bar, and links to Models, Datasets, Spaces, Posts, Docs, Solutions, Pricing, and Log In. Below the navigation bar, the left sidebar shows a 'Tasks' section with a search bar and a 'Reset Tasks' button. The main content area is titled 'Models 70,402' and includes a 'Filter by name' search bar. A list of models is displayed in a grid, each with its name, a brief description, and statistics. The models listed include:

- databricks/dbrx-instruct**: Text Generation • Updated about 16 hours ago • 9.36k • 529
- ai21labs/Jamba-v0.1**: Text Generation • Updated about 11 hours ago • 293 • 450
- xai-org/grok-1**: Text Generation • Updated about 18 hours ago • 31.3k • 1.8k
- databricks/dbrx-base**: Text Generation • Updated about 16 hours ago • 1.68k • 294
- mistralai/Mistral-7B-Instruct-v0.2**: Text Generation • Updated 5 days ago • 2.09M • 1.49k
- Nexusflow/Starling-LM-7B-beta**: Text Generation • Updated 2 days ago • 5.7k • 174
- google/gemma-7b**: Text Generation • Updated 30 days ago • 163k • 2.65k
- alpindale/Mistral-7B-v0.2-hf**: Text Generation • Updated 4 days ago • 8.35k • 121
- meta-llama/Llama-2-7b-chat-hf**: Text Generation • Updated 10 days ago • 1.36M • 3.22k
- mistralai/Mixtral-8x7B-Instruct-v0.1**: Text Generation • Updated 29 days ago • 965k • 3.5k
- stabilityai/stable-code-instruct-3b**: Text Generation • Updated 1 day ago • 1.76k • 82
- NousResearch/Hermes-2-Pro-Mistral-7B**: Text Generation • Updated about 14 hours ago • 38.7k • 347
- Qwen/Qwen1.5-MoE-A2.7B**: Text Generation • Updated about 20 hours ago • 124 • 60
- hpc-ai-tech/grok-1**: Text Generation • Updated 1 day ago • 1.15k • 56
- CohereForAI/c4ai-command-r-v01**: Text Generation • Updated about 20 hours ago • 27.1k • 750
- meta-llama/Llama-2-7b**: Text Generation • Updated 10 days ago • 3.74k
- mistralai/Mistral-7B-v0.1**: Text Generation • Updated Dec 11, 2023 • 2.78M • 3.03k
- mLabonne/Beyonder-4x7B-v3**: Text Generation • Updated about 13 hours ago • 739 • 41

Большие языковые модели

Прoxy для API сервисов LLM

<https://openrouter.ai/models>



Большие языковые модели

предобученные и модифицированные модели для русского языка

<https://huggingface.co/ai-forever>

<https://huggingface.co/IlyaGusev>

Models 79 🔍

Sort: Recently Updated

Model Name	Category	Updated	Downloads	Likes
ai-forever/kandinsky3-diffusers		Feb 20	13	2
ai-forever/ruT5-base	Text2Text Generation	Dec 11, 2023	5.92k	13
ai-forever/FRED-T5-large	Text2Text Generation	Dec 5, 2023	2.46k	17
ai-forever/mGPT	Text Generation	Dec 5, 2023	47k	218
ai-forever/rugpt2large		Dec 5, 2023	411	7
ai-forever/ruT5-large	Text2Text Generation	Dec 28, 2023	659	32
ai-forever/FRED-T5-1.7B	Text2Text Generation	Dec 5, 2023	4.04k	63
ai-forever/mGPT-13B	Text Generation	Dec 5, 2023	1.51k	46
ai-forever/ruGPT-3.5-13B	Text Generation	Dec 5, 2023	3.82k	215
ai-forever/rugpt3small_based_on_gpt2	Text Generation	Dec 5, 2023	11.8k	25

Большие языковые модели

квантование LLM

может уменьшать размер базовой модели на порядок
путём снижения точности (количества бит) вычислений (float32 в int8)
при некритичном понижении качества результата

снижаются требования к производительности аппаратуры

системы инференса квантованных моделей - Ollama, vLLM



Большие языковые модели

Prompting — правила конструирования запросов для LLM

- обозначение роли
- чёткая формулировка задачи
- определение формата ответа
- примеры вопросов и ответов

Литература

Литература

Борисов Е.С. Методы машинного обучения. 2024
https://github.com/mechanoid5/ml_lectorium_2024_I

Борисов Е.С. Методы обработки текстов на естественном языке. 2024
https://github.com/mechanoid5/ml_nlp_2024_I

Майоров В.Д. Основы обработки текстов. 10. Языковые модели. ИСП РАН, 2021
https://www.youtube.com/watch?v=_8MGdpt4I9M

Тихомиров М.М. Основы обработки текстов. 14. Большие языковые модели. ИСП РАН, 2023
https://www.youtube.com/watch?v=EC6_rMs1vsY

Нейчев Радослав Self-Attention. Transformer overview. Лекторий ФПМИ, 2020
<https://www.youtube.com/watch?v=UETKUIlYE6g>

Jay Alammar Transformer в картинках. (Перевод - Е.Смирнова, С. Шкарин)
<https://habr.com/ru/articles/486358/>

Jay Alammar GPT-2 в картинках. (Перевод - Е.Смирнова, С. Шкарин)
<https://habr.com/ru/articles/490842/>